Tam RAG Ablation Sonuçları

Teknik toplantı özeti - 6 model, 4 RAG yöntemi, 100 soru - 15.07.2026

En yüksek model ortalaması gemma4:26b: 6.97/10. En güçlü kombinasyon gemma4:26b + Smart Vector: 7.46/10. Yöntem düzeyinde Classic Vector, Smart Vector ile benzer kaliteyi daha düşük gecikmeyle verdi.

Bu rapor, güvenlik-kritik 100 sorunun her model-yöntem kombinasyonunda OpenAI tabanlı otomatik değerlendiriciyle puanlandığı 2.400 başarılı inference ve evaluation satırını özetler. Otomatik skorlar karşılaştırma sinyalidir; alan uzmanı kabul testi değildir.

Kaynak CSV	data/results/rag_ablation_100_resume_20260715/merged_results.csv
Kapsam	6 model x 4 RAG yöntemi x 100 soru = 2.400 sonuç
Başarı durumu	2.400 inference ok; 2.400 evaluation ok
Değerlendirme	OpenAI / gpt-5.4-mini
Ollama ayarları	timeout=300, num_predict=512, temperature=0, seed=42
Retrieval	k=10; vector ve BM25; classic ve smart chunking

1. Teknik Özet

- Kalite lideri: gemma4:26b - ortalama 6.97/10; doğru 210/400.
- En iyi tek koşul: gemma4:26b + Smart Vector - 7.46/10; doğru 60/100.
- Yöntem dengesi: Classic Vector kalite lideri (6.78); Classic Vector hız lideri (8.1 sn).
- Genel güvenlik sinyali: 194/2.400 sonuç yüksek risk olarak etiketlendi (%8.1).
- Operasyonel bulgu: gemma4:e4b model bazında en düşük ortalama gecikmeyi verdi (8.2 sn); ancak seçim kalite, risk ve gecikmeyle birlikte yapılmalı.

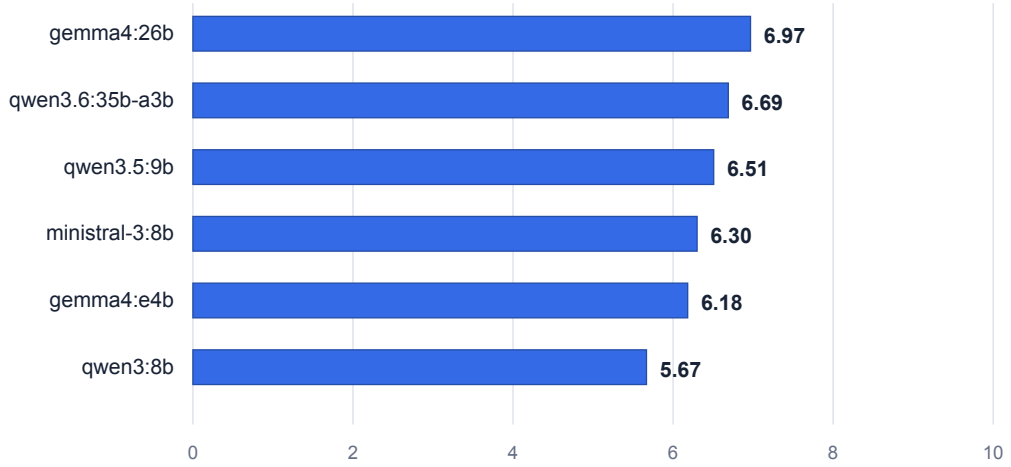
Ana karar

Genel varsayılan için gemma4:26b + Classic Vector güçlü bir hız/kalite adayıdır (7.27/10, 7.2 sn, 2 yüksek risk). Mutlak kalite önceliğinde gemma4:26b + Smart Vector liderdir (7.46/10), ancak ortalama gecikme 13.1 saniyeye çıkar.

2. Model Karşılaştırması

Gemma4:26b toplam kalite lideri; Qwen3.6:35b-a3b ikinci sırada ve daha yüksek token üretim hızı sunuyor. Grafik, her model için dört RAG yönteminin 400 sonuç üzerindeki ortalamasını gösterir.

Model bazında ortalama kalite skoru

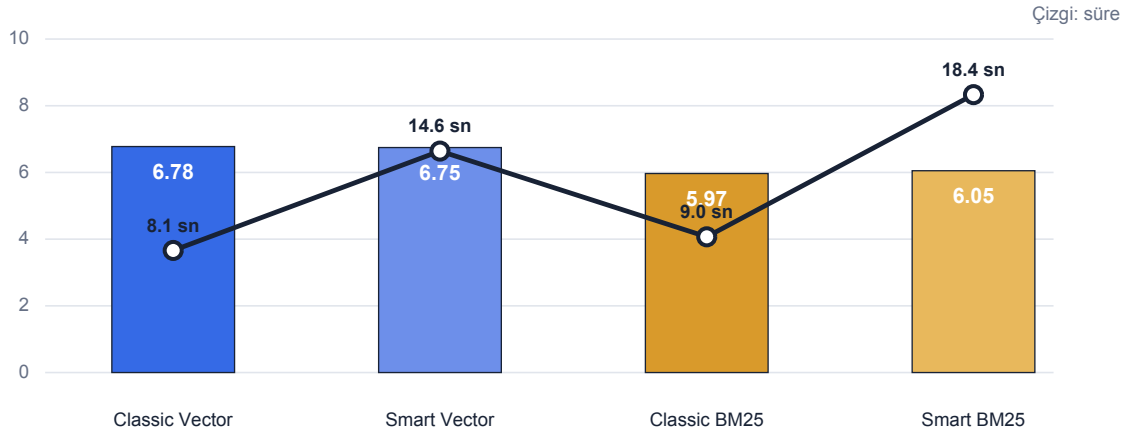


Model	Skor	Doğru	Yanlış	Yüksek risk	Ort. sn	TPS
gemma4:26b	6.97	210/400	80/400	20/400	11.2	27.9
qwen3.6:35b-a3b	6.69	187/400	84/400	20/400	13.0	33.3
qwen3.5:9b	6.51	177/400	89/400	34/400	13.9	21.8
ministral-3:8b	6.30	165/400	99/400	54/400	15.8	20.8
gemma4:e4b	6.18	158/400	93/400	28/400	8.2	27.7
qwen3:8b	5.67	131/400	122/400	38/400	13.0	22.3

3. RAG Yöntemi Karşılaştırması

Classic Vector ve Smart Vector kalite açısından neredeyse eşit. Classic Vector ortalama 8.1 saniye ile Smart Vector'ın 14.6 saniyelik gecikmesine göre daha verimli. BM25 yöntemleri bu veri setinde hem skor hem yanlış cevap oranında geride kaldı.

RAG yöntemlerinde kalite ve gecikme



Yöntem	Skor	Doğru	Kısmi	Yanlış	Yüksek risk	Ort. sn
Classic Vector	6.78	269/600	223/600	108/600	31/600	8.1
Smart Vector	6.75	290/600	190/600	120/600	47/600	14.6
Smart BM25	6.05	238/600	195/600	167/600	50/600	18.4
Classic BM25	5.97	231/600	197/600	172/600	66/600	9.0

4. Model - Yöntem Matrisi

En iyi kombinasyonların tamamı vector retrieval kullanıyor. Aşağıdaki matris ortalama AI skorunu gösterir; koyu hücreler daha yüksek skoru ifade eder.

Model	Classic Vector	Smart Vector	Classic BM25	Smart BM25
gemma4:26b	7.27	7.46	6.54	6.60
qwen3.6:35b-a3b	7.30	7.04	6.08	6.34
qwen3.5:9b	6.89	6.72	6.10	6.32
ministral-3:8b	6.46	6.51	6.06	6.17
gemma4:e4b	6.46	6.70	5.78	5.79
qwen3:8b	6.28	6.05	5.25	5.09

Öne çıkan kombinasyonlar

- gemma4:26b + Smart Vector: 7.46/10, 60/100 doğru, 5/100 yüksek risk, 13.1 sn.
- qwen3.6:35b-a3b + Classic Vector: 7.30/10, 50/100 doğru, 1/100 yüksek risk, 7.5 sn.
- gemma4:26b + Classic Vector: 7.27/10, 52/100 doğru, 2/100 yüksek risk, 7.2 sn.
- qwen3.6:35b-a3b + Smart Vector: 7.04/10, 51/100 doğru, 4/100 yüksek risk, 15.5 sn.
- qwen3.5:9b + Classic Vector: 6.89/10, 45/100 doğru, 8/100 yüksek risk, 9.4 sn.

5. Risk, Gecikme ve Yorumlama Sınırları

Toplam 194 yüksek risk etiketi gözlendi. En düşük kombinasyon düzeyi yüksek risk sayısı Qwen3.6:35b-a3b + Classic Vector'da 1/100; en yüksek değer Ministral-3:8b + Classic BM25'te 18/100. Yüksek risk sayısı tek başına kaliteyi açıklamaz; yanlış/kısmi cevap dağılımıyla birlikte okunmalıdır.

Kombinasyon	Skor	Yüksek risk	Yanlış	Ort. sn
qwen3.6:35b-a3b / Classic Vector	7.30	1/100	12/100	7.5
gemma4:26b / Classic Vector	7.27	2/100	14/100	7.2
qwen3.6:35b-a3b / Smart Vector	7.04	4/100	18/100	15.5
gemma4:26b / Smart Vector	7.46	5/100	16/100	13.1
qwen3:8b / Smart BM25	5.09	11/100	39/100	19.9
qwen3:8b / Classic BM25	5.25	14/100	36/100	8.7
ministral-3:8b / Smart Vector	6.51	17/100	25/100	18.3
ministral-3:8b / Classic BM25	6.06	18/100	28/100	11.6

Robustluk ve sınırlamalar

- Sonuçlar aynı 100 soru üzerinde tekrarlı karşılaştırmadır; soru başına yalnızca bir deterministik üretim vardır.
- AI skoru ve risk etiketi gpt-5.4-mini değerlendirmesine dayanır; klinik/alan uzmanı değerlendirmesiyle kalibre edilmemiştir.
- Gecikme; retrieval, ağ ve model üretimini içerir ve paylaşımlı donanım/ağ koşullarından etkilenebilir.
- Skor farkları için güven aralığı veya eşleştirilmiş anlamlılık testi bu özet raporda hesaplanmamıştır.
- Türkçe risk etiketleri normalizasyon sırasında high/low sınıflarına eşlenmiştir (5 satır).

6. Karar ve Sonraki Adımlar

Bu koşu, vector retrieval'ın BM25'e göre daha güvenilir bir başlangıç noktası olduğunu gösteriyor. Üretim adayı seçimi için kalite liderini tek başına almak yerine gecikme ve yüksek risk dağılımını birlikte optimize etmek gerekir.

Karar alanı	Öneri
Genel varsayılan	gemma4:26b + Classic Vector: 7.27 skor, 7.2 sn, 2 yüksek risk.
Maksimum kalite	gemma4:26b + Smart Vector: 7.46 skor; 13.1 sn gecikme kabul edilebiliyorsa.
Hızlı güçlü alternatif	Qwen3.6:35b-a3b + Classic Vector: 7.30 skor, 7.5 sn, 1 yüksek risk.
Retrieval yönü	Vector yöntemlerini ana çizgi yap; BM25'i hibrit/fallback hipotezi olarak ayrıca test et.
Güvenlik doğrulaması	Yanlış ve yüksek riskli cevapları alan uzmanıyla kör incele; evaluator uyumunu ölç.
Sonraki benchmark	En iyi 2-3 kombinasyonda tekrarlı koşu, confidence interval ve soru kategorisi kırılımı ekle.

Açık sorular

- Hangi soru kategorilerinde Smart Vector gerçekten katkı sağlıyor?
- Yüksek risk etiketleri alan uzmanı değerlendirmesiyle ne kadar örtüşüyor?
- İki güçlü kombinasyon arasında tekrarlı koşularda skor sıralaması korunuyor mu?

Kaynak: merged_results.csv, manifest.csv ve atomik checkpoint CSV'leri. Bu PDF toplantı özeti olarak tasarlanmıştır; satır düzeyi audit final CSV üzerinden yapılmalıdır.