RAG KV-cache karsilastirmasi

Qwen3.6 ve Gemma4 - F16, q8_0 ve q4_0

Altı koşu aynı 120 soru ve aynı dondurulmuş Classic Vector bağlamlarıyla çalıştı. Sistem prompt'u ve prompt cache açıktı.

720/720	Classic Vector	Prompt cache acik
basarili eval	tek RAG yontemi	tum kosullar

Kısa sonuç

KV türleri iki modelde de sonucu az değiştirdi. Gemma daha yüksek değerlendirme skoru aldı. Qwen token üretiminde daha hızlı kaldı.

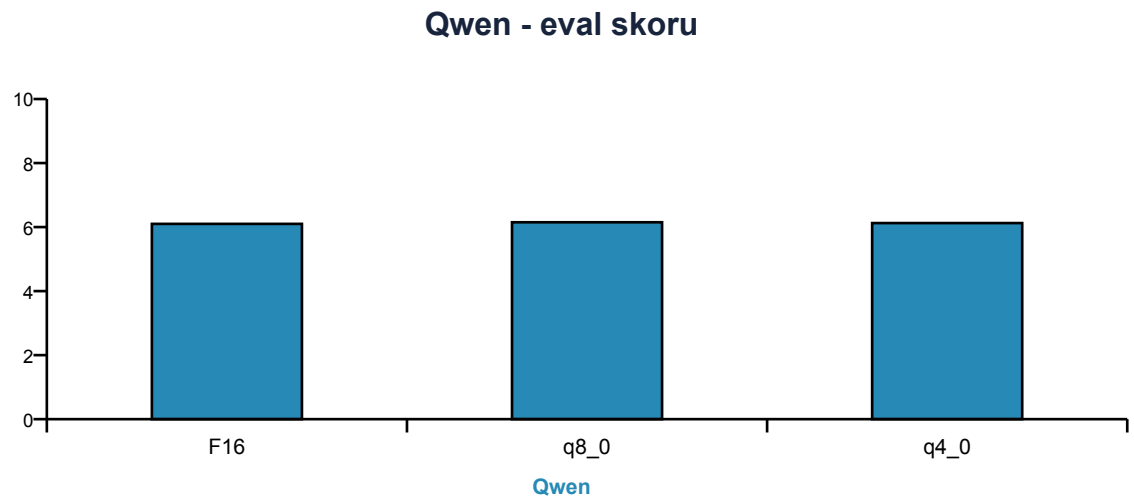
Classic Vector 81 soruda bağlam buldu. 39 soru eşik üstü parça olmadığı için prompt'un bağlamsız koluyla yanıtlandı. Bu dağılım tüm koşullarda aynıydı.

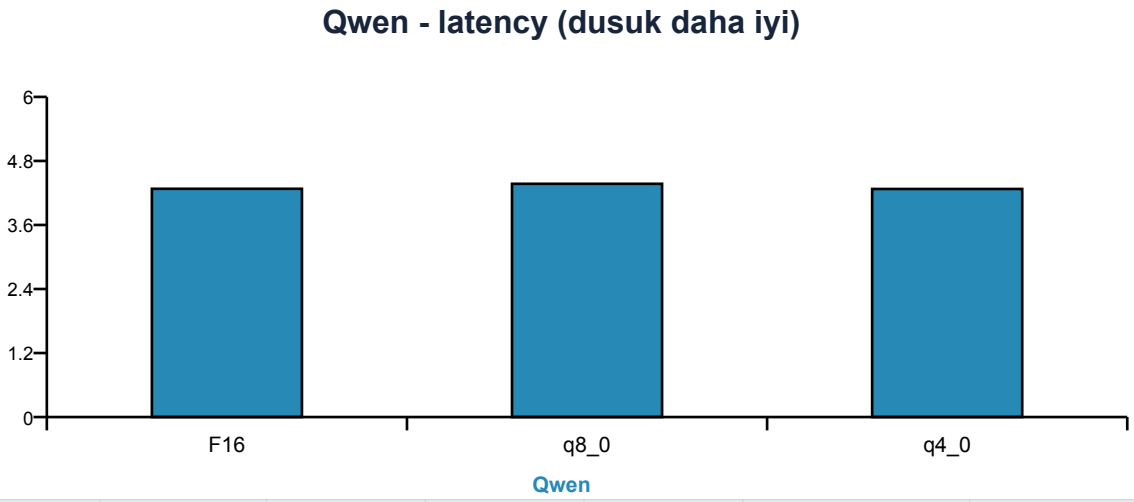
Koşullar

Q4_K_M ağırlık, ctx 32768, parallel 1, Flash Attention açık, temperature 0, max_tokens 512. Değerlendirici: OpenAI gpt-5.4-mini.

1. Qwen

Üç KV türü birbirine çok yakın. q8_0 en yüksek skoru aldı; fark yalnızca 0.05 puan. F16 üretim hızında küçük bir üstünlük gösterdi.

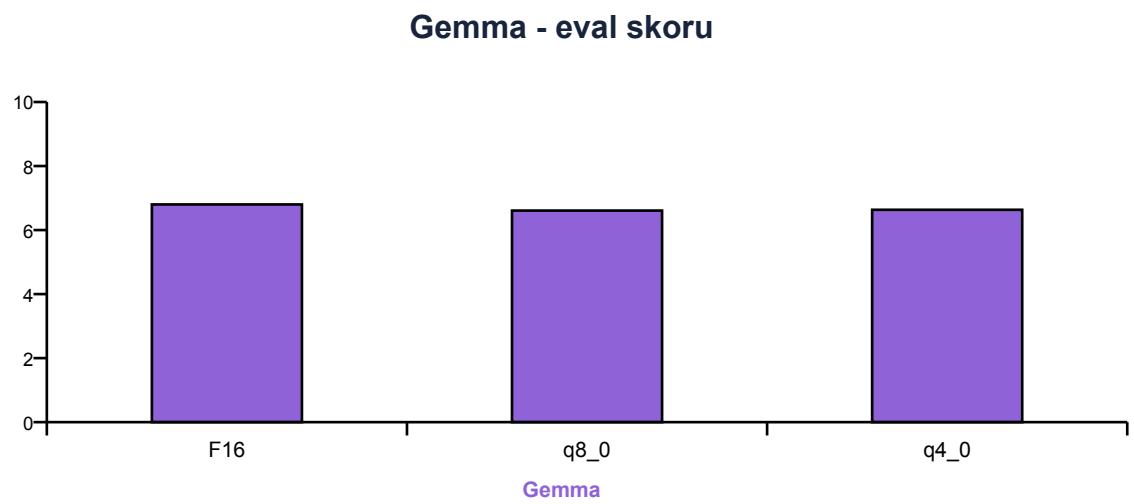


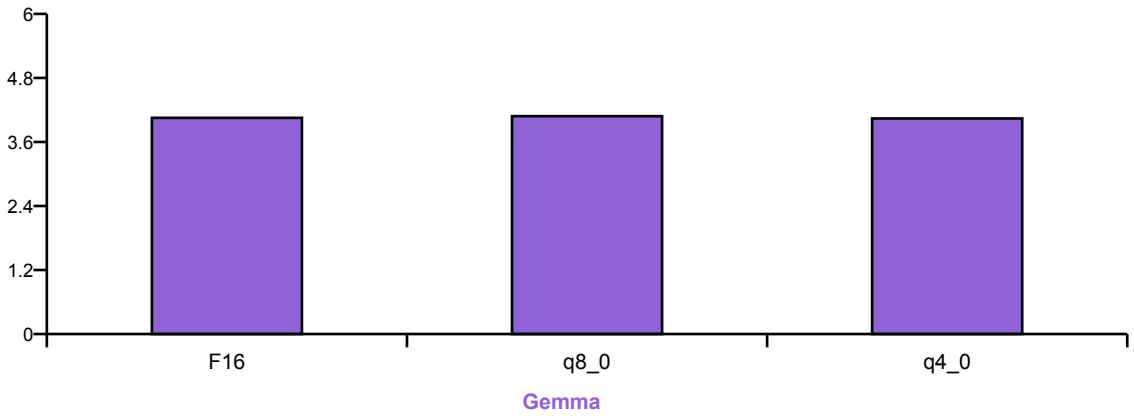


KV	Skor	Dogru	Kismi	Yanlis	Latency	tok/sn
F16	6.10	47	39	34	4.28 sn	37.41
q8_0	6.15	45	42	33	4.37 sn	36.67
q4_0	6.12	46	42	32	4.27 sn	36.49

2. Gemma

Gemma'da F16 en iyi skoru verdi. q8_0 ve q4_0 biraz geride kaldı. Latency farkı yok denecek kadar küçük.

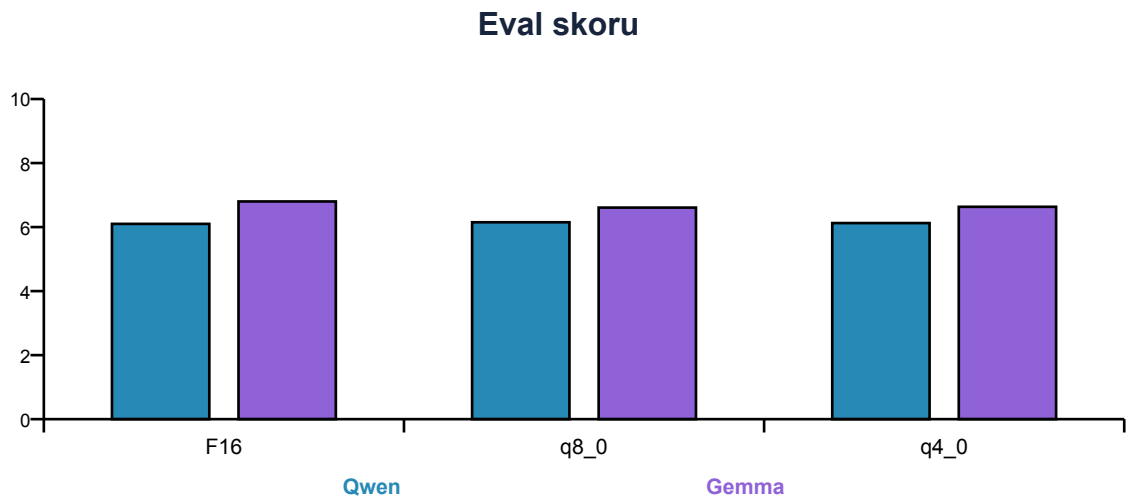


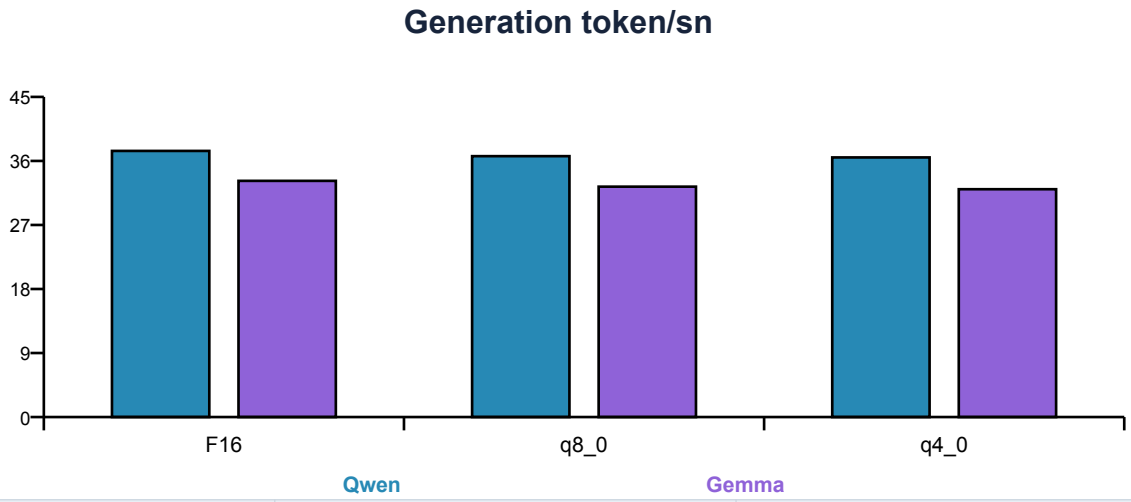


KV	Skor	Dogru	Kismi	Yanlis	Latency	tok/sn
F16	6.80	60	35	25	4.05 sn	33.20
q8_0	6.61	57	36	27	4.08 sn	32.38
q4_0	6.63	56	37	27	4.04 sn	32.02

3. Qwen vs. Gemma

Gemma her KV türünde daha yüksek skor ve daha fazla doğru yanıt üretti. Qwen ise her koşulda daha yüksek token/sn değerine ulaştı.





Ölçüt	Qwen	Gemma
En iyi eval	q8_0 - 6.15	F16 - 6.80
En yüksek doğru	F16 - 47	F16 - 60
En hızlı üretim	F16 - 37.41 tok/sn	F16 - 33.20 tok/sn
Pratik seçim	KV türleri yakın	Kalite için F16

Sonuç: KV quantization bu kısa bağlamlı testte belirgin hız kazancı getirmedi. Kalite önceliğinde Gemma F16; üretim hızı önceliğinde Qwen F16 en net seçenek.