Qwen3.6 Prompt Karşılaştırması

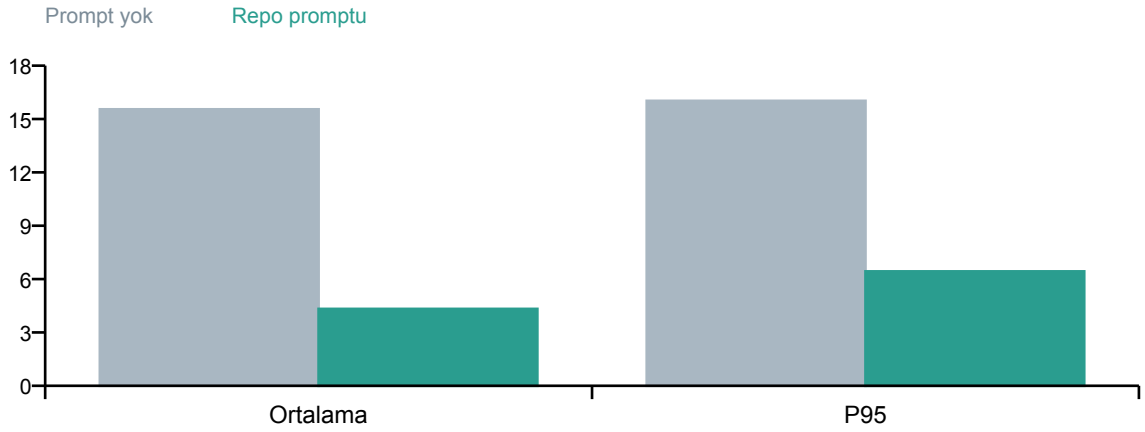
Prompt yok vs. repo no-RAG promptu - 100 soru - aynı llama.cpp config

Repo promptu ortalama yanıt süresini 15.54 saniyeden 4.32 saniyeye indirdi. Modelin gerçek üretim hızı değişmedi; fark, cevapların daha kısa ve doğal biçimde tamamlanmasından geldi.

-72%	93% → 0%	499 → 124	33.10 → 33.28
ortalama süre	**kesilen cevap**	**token / cevap**	**token/sn**
15.54 → 4.32 sn	512 token sınırı	ortalama çıktı	üretim hızı aynı

Yanıt süresi belirgin biçimde düştü

Prompt olmadan model çoğu cevapta 512 token sınırına kadar devam etti. Repo promptu kısa ve düz metin istediği için cevaplar daha erken tamamlandı.



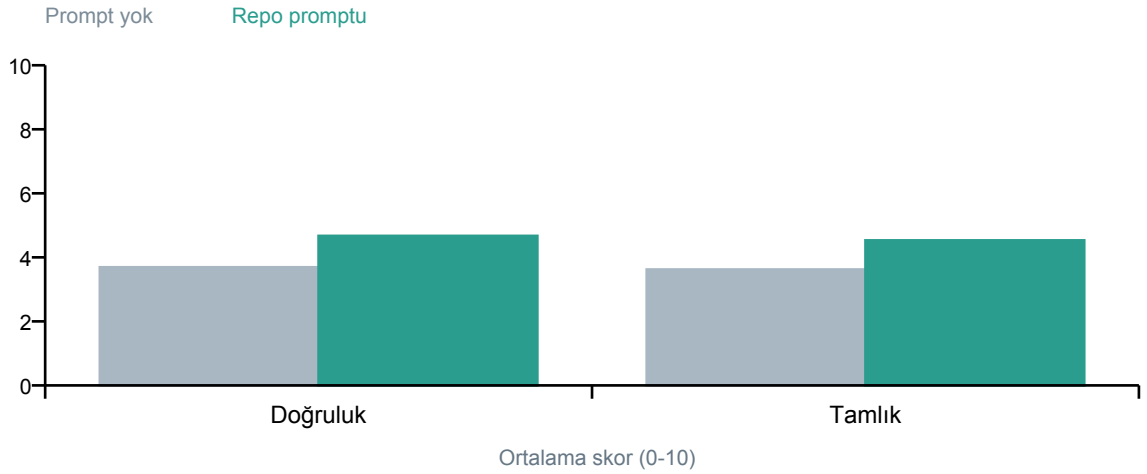
Saniye - düşük değer daha iyi

Cihaz hızı değil, cevap uzunluğu değişti

İki koşuda da üretim hızı yaklaşık 33 token/sn kaldı. Prompt, modeli hızlandırmadı; gereksiz token üretimini azalttı.

Kalite de iyileşti

Doğruluk 3.69'dan 4.67'ye, tamlık 3.62'dan 4.53'ye çıktı. Yine de model bilgisi ve referansla uyum tarafında geliştirme alanı var.



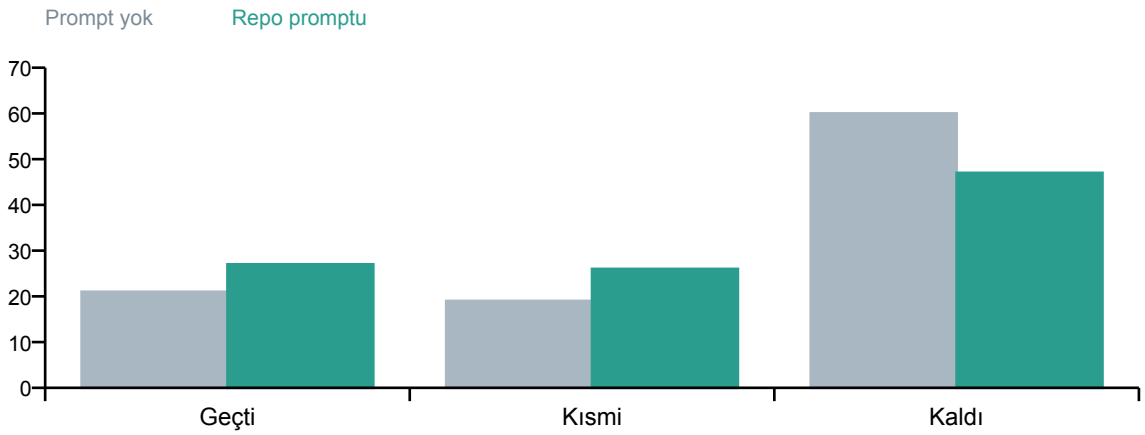
En önemli bulgu

Kesilen cevap oranı 93%'ten 0%'a düştü

Repo promptuyla 100 cevabın tamamı doğal stop ile bitti.

Değerlendirme dağılımı

Geçen cevap sayısı arttı, kalan cevap sayısı azaldı. Yüksek halüsinasyon riski de 65'ten 42'ye düştü.



Sonuç

Repo promptu doğru varsayılan seçim. Ortalama süre 72% azaldı ve kalite yükseldi. Buna rağmen 47 cevap hâlâ başarısız; sonraki çalışma retrieval bağlamı ve groundedness değerlendirmesine odaklanmalı.

Not: İki koşuda model, quantization, KV cache, Flash Attention, max_tokens=512 ve temperature=0 aynıdır. Tek fark soru promptudur. Model yükleme ve warmup süreleri ölçüme dahil değildir.