Qwen3.6 RAG Ablation

120 soruluk blind gold set - 4 retrieval yöntemi - 480 değerlendirme

Ana bulgu: Smart BM25 en yüksek ortalama kaliteyi verdi (7.80/10). En hızlı yöntem Classic Vector (4.2 sn); kalite liderinin ortalaması 23.5 sn.

Model	Qwen3.6-35B-A3B
Embedding	embeddinggemma:300m
Judge	OpenAI gpt-5.4-mini
Koşu	120 soru x 4 yöntem; temperature=0; seed=42; k=10
Bütünlük	480/480 inference ok; 480/480 evaluation ok
Tarih	19.07.2026 21:32

1. Yönetici Özeti

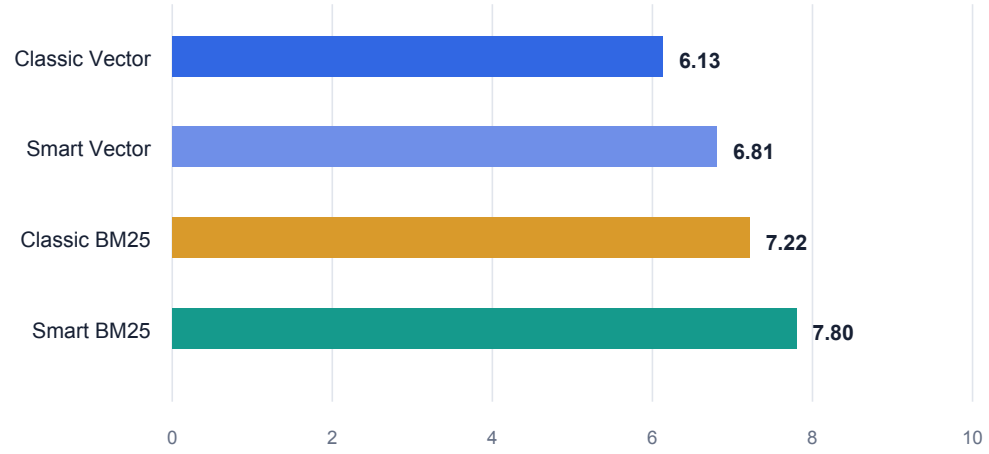
Genel ortalama judge skoru 6.99/10. Toplam 480 yanıtta 236 doğru, 151 kısmi ve 93 yanlış kararı verildi. Risk dağılımı 387 düşük, 76 orta ve 17 yüksek risk olarak etiketlendi.

Kalite lideri Smart BM25, Classic Vector taban çizgisine göre soru başına ortalama +1.67 puan fark oluşturdu; 56 soruda daha yüksek, 20 soruda daha düşük skor aldı. Bu kazanç gecikme maliyetiyle birlikte değerlendirilmelidir.

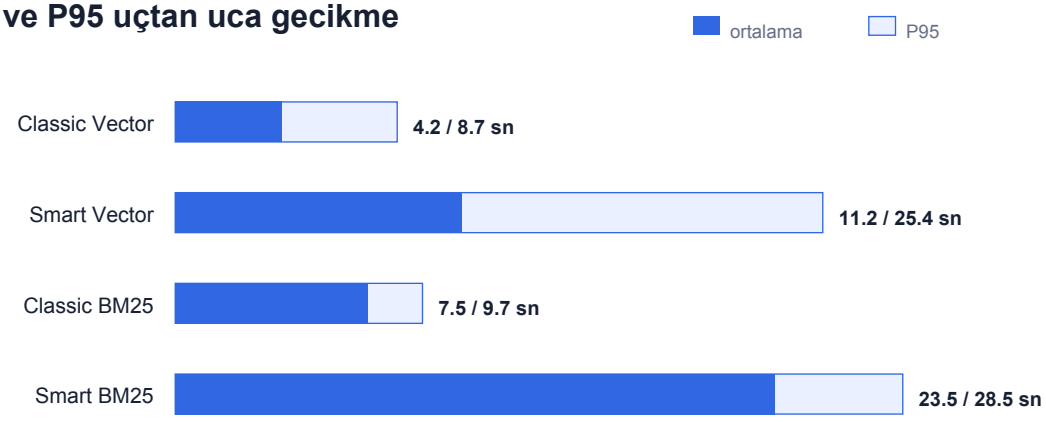
Yöntem	Skor	Medyan	Doğru	Kısmi	Yanlış	Yüksek risk	Ort./P95 sn
Classic Vector	6.13	6.0	47	38	35	4	4.2/8.7
Smart Vector	6.81	8.0	59	34	27	6	11.2/25.4
Classic BM25	7.22	9.0	62	40	18	3	7.5/9.7
Smart BM25	7.80	9.0	68	39	13	4	23.5/28.5

2. Kalite ve Gecikme

Yöntem bazında kalite skoru



Ortalama ve P95 uçtan uca gecikme



3. Retrieval Davranışı

Yöntem	Ort. chunk	Boş bağlam	TPS	Kalite / sn
Classic Vector	3.96	39	36.9	1.474
Smart Vector	4.32	25	36.6	0.607
Classic BM25	10.00	0	36.9	0.958
Smart BM25	10.00	0	35.4	0.333

Yorum

Bu koşuda BM25 tabanlı yöntemler vector yöntemlerinden daha yüksek judge skoru üretti. Smart BM25 kalite lideri olurken Classic Vector en düşük gecikmeyi verdi. Smart yöntemlerde parent içerik kullanımı bağlamı büyüttüğü için gecikme belirgin şekilde arttı; bu nedenle üretim context'i 32768 token olarak çalıştırıldı.

Karar önerisi

Kalite önceliğinde Smart BM25 ana adaydır. Düşük gecikmeli varsayılan gerekiyorsa Classic Vector ayrı aday olarak tutulmalı; iki yöntem soru kategorileri bazında yeniden karşılaştırılmalıdır. Tek ortalama skorla nihai üretim kararı verilmemelidir.

4. Zayıf Sorular ve Risk

Aşağıdaki sorular dört yöntemin ortalamasında en düşük judge skoruna sahip örneklerdir. Satır düzeyi inceleme için merged_results.csv kullanılmalıdır.

#	Soru	Ort. skor	En iyi	En düşük
82	Ghost TR 01'de istem dışı ateşlemeyi önleyen ve silahın durumunu gösteren hangi düzenekle...	1.00	Classic Vector 1	Classic Vector 1
53	Göğüs kemiği için kullanılan kemik içi set ile kol veya kaval kemiği için kullanılan set,...	1.25	Classic Vector 2	Smart BM25 0
25	Görev öncesi M9 çantasını yanık bakımı ve pasif ısı koruması için kontrol eden ekip, Yanı...	1.75	Classic BM25 3	Classic Vector 1
87	Açık alan görevinden dönen MP-5 temizlenip tetik grubu sökülürken, gaz yolları ile küçük ...	1.75	Classic Vector 2	Classic BM25 1
51	Taşıma aşamasında üst solunum geçidi kapanmak üzereyken, gırtlak üstüne oturan araç ile s...	1.75	Classic Vector 7	Smart Vector 0
99	Ele geçirilen RPG-7 için kimliklendirme prosedüründe önce ekip ve atım hızı nasıl kaydedi...	2.00	Smart BM25 7	Classic Vector 0

Sınırlamalar

• Her soru-yöntem çifti için tek deterministik üretim vardır; tekrarlı koşu güven aralığı hesaplanmamıştır.

• Kalite ve risk etiketleri gpt-5.4-mini judge modeline dayanır; alan uzmanı değerlendirmesi değildir.

• Gecikme retrieval, SSH tüneli, llama.cpp üretimi ve paylaşımlı donanım koşullarından etkilenebilir.

• BM25 üstünlüğü bu doküman koleksiyonu ve blind120 soru dağılımına özgüdür; başka korpuslara doğrudan genellenmemelidir.

Kaynak: data/results/rag_ablation_blind120_qwen36_llamacpp_ctx32768_20260719/merged_results.csv. Rapor metrikleri yalnızca doğrulanmış 480 satırdan dinamik olarak hesaplandı.