# Qwen3.6 vs Gemma4

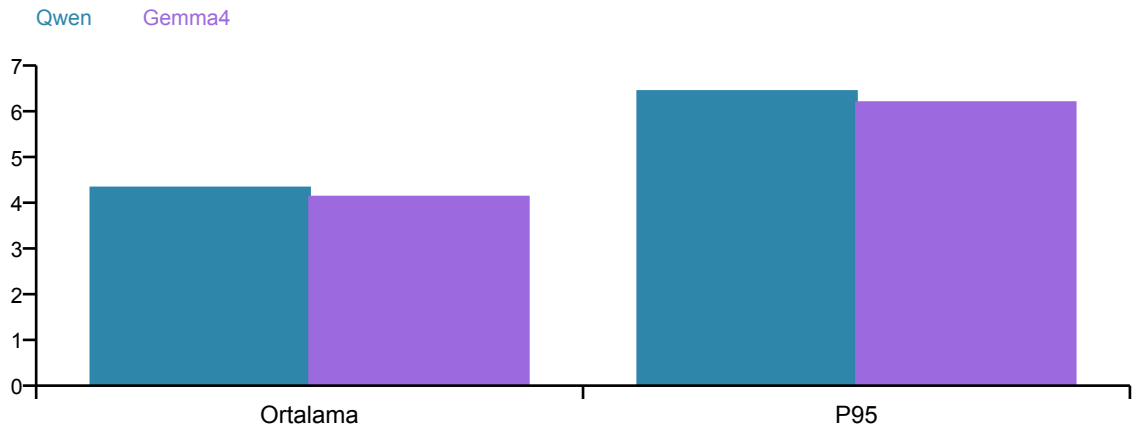
Repo promptu açık - 100 soru - Q4_K_M / KV Q8 - aynı llama.cpp ayarları

İki model de yaklaşık 33 token/sn üretti ve tüm cevapları doğal biçimde tamamladı. Gemma4 biraz daha düşük latency verdi; Qwen kalite skorlarında çok az önde kaldı.

| 4.32 / 4.12 | 33.28 / 33.21 | 124 / 123 | 0 / 0 |
|---|---|---|---|
| **ortalama süre** | **token/sn** | **token / cevap** | **kesilen cevap** |
| Qwen / Gemma4 - saniye | Qwen / Gemma4 | Qwen / Gemma4 | Qwen / Gemma4 |

## Performans neredeyse aynı

Gemma4 ortalamada yaklaşık 0.2 saniye daha hızlı. P95 farkı da küçük; gerçek üretim hızında anlamlı bir ayrım yok.



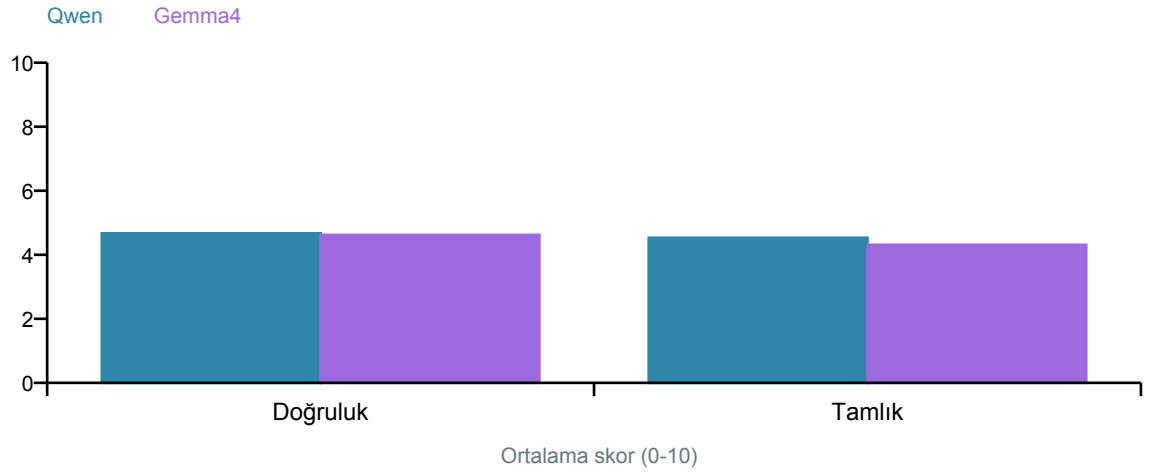

Saniye - düşük değer daha iyi

## Cevap uzunluğu da aynı seviyede

Qwen ortalama 124, Gemma4 123 token üretti. İki modelde de 512-token kesilmesi görülmedi.

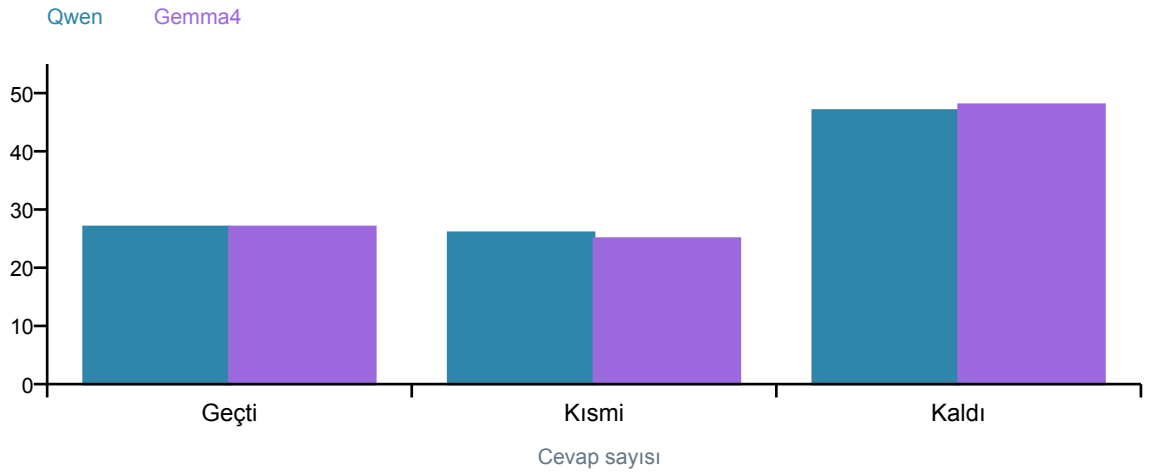
# Kalitede Qwen çok az önde

Qwen doğrulukta 4.67, Gemma4 4.62 aldı. Tamlık skorları sırasıyla 4.53 ve 4.31. Fark küçük; iki model de aynı sayıda cevabı geçti.




## Değerlendirme dağılımı

Her iki modelde de 27 cevap geçti. Qwen 47, Gemma4 48 başarısız cevap verdi.




### Cache farkı

**Qwen: 0.7%** **Gemma4: 61.3%**

Gemma4 ortak prompt prefix'ini daha fazla cache'den kullandı. Bu fark generation token/sn ölçümünü değiştirmedi.

## Sonuç

Qwen kalite tarafında çok az önde; Gemma4 latency tarafında çok az önde. Yüksek halüsinasyon riski Qwen'de 42, Gemma4'te 43. Bu testte iki model arasında net bir kazanan yok.

Not: Model yükleme ve warmup süreleri dahil değildir. Her iki koşuda repo no-RAG promptu, max_tokens=512, temperature=0 ve tek slot kullanılmıştır.