Classic Vector RAG
KV-Cache Karşılaştırması

150 soru | Gemma + Qwen | f16, q8_0, q4_0 | 900 değerlendirme

Bu rapor aynı Classic Vector RAG bağlamları altında iki model ve üç simetrik KV-cache tipini karşılaştırır. Tüm koşullar aynı 150 soru, dondurulmuş retrieval bağlamları ve üretim ayarlarını kullanır.

1. Deney Tasarımı

Bileşen	Değer
Soru seti	final_qa_150.csv - sabit 150 soruluk mühendislik benchmark'ı
RAG	Classic Vector; embeddinggemma:300m; k=10; threshold=0.55
Modeller	Gemma4 26B-A4B ve Qwen3.6 35B-A3B; Q4_K_M ağırlık
Değişken	Simetrik K/V cache: f16, q8_0, q4_0
Sabit üretim	ctx 32768; parallel 1; Flash Attention açık; prompt cache kapalı; temperature 0; max 512
Jüri	gpt-5.4-mini; reasoning_effort=high; balanced-v2
Başarı	900/900 inference ve 900/900 değerlendirme başarılı

Dondurulmuş bağlam doğrulaması

Altı koşulun retrieved_chunks alanları frozen_contexts.jsonl ile birebir doğrulandı. Bu nedenle model ve KV farkları retrieval değişiminden kaynaklanmaz. Classic Vector 116 soruda en az bir chunk döndürdü; 34 soruda threshold nedeniyle bağlam boştu.

Bu sabit benchmark held-out genelleme kanıtı değildir; sonuçlar bu donanım, soru seti ve tek-istek protokolüne aittir.

2. Sonuç Tablosu

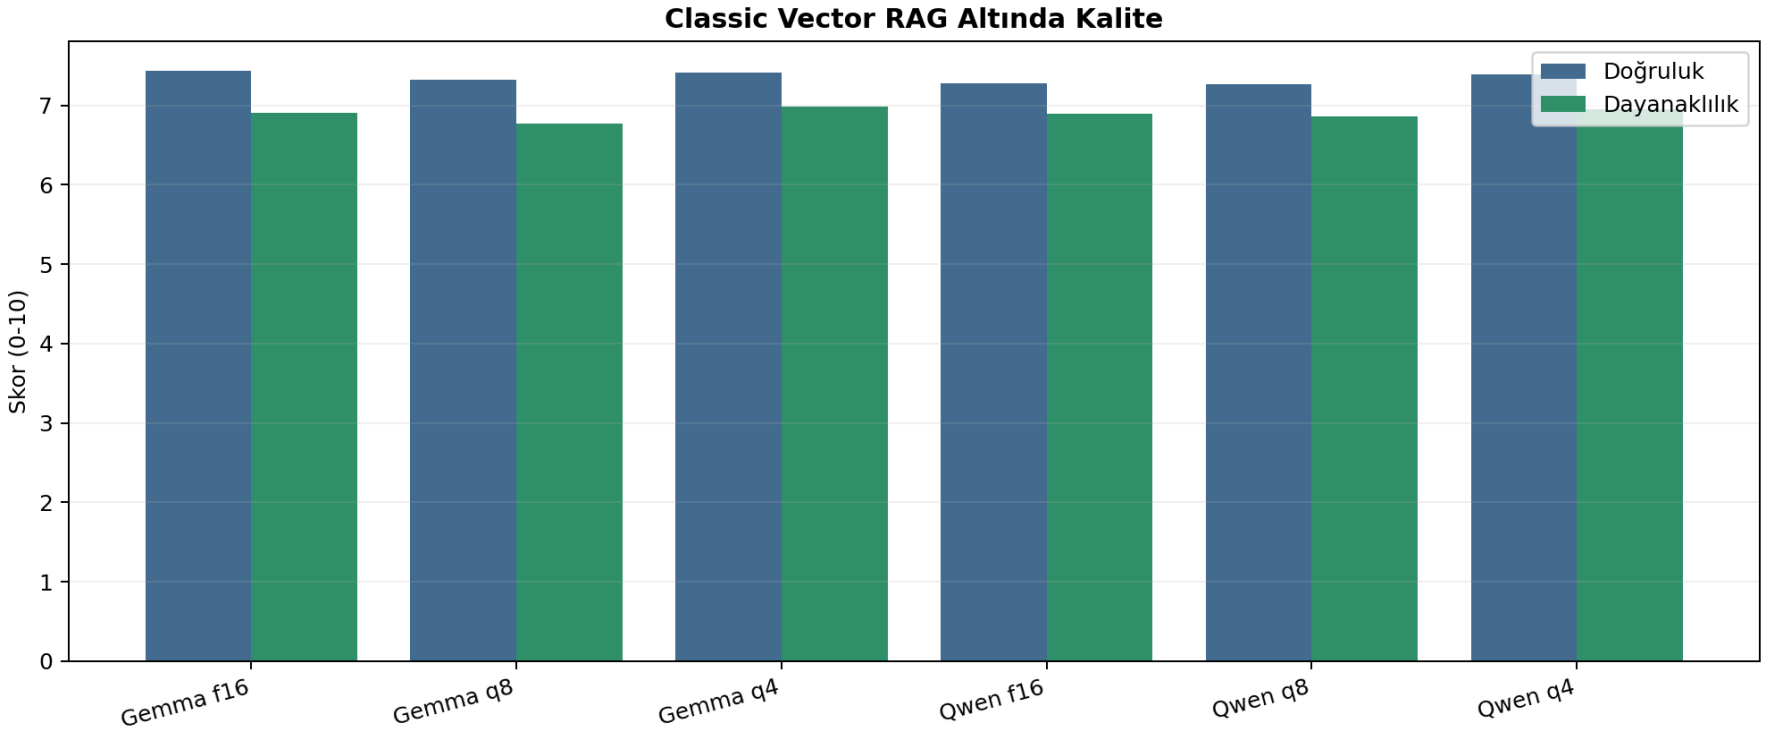
Koşul	Doğr.	Eksik.	Day.	Pass	Fail	High risk	Ort. sn	p95 sn	Tok/sn
Gemma f16	7.44	6.75	6.91	88	35	26	4.18	6.88	32.98
Gemma q8	7.33	6.69	6.77	85	32	25	4.22	7.09	32.23
Gemma q4	7.41	6.80	6.99	87	32	23	4.20	7.39	31.78
Qwen f16	7.27	6.30	6.90	83	36	37	4.56	7.81	37.39
Qwen q8	7.27	6.35	6.86	85	33	34	4.59	7.90	36.77
Qwen q4	7.39	6.45	6.95	86	34	33	4.63	7.98	36.32

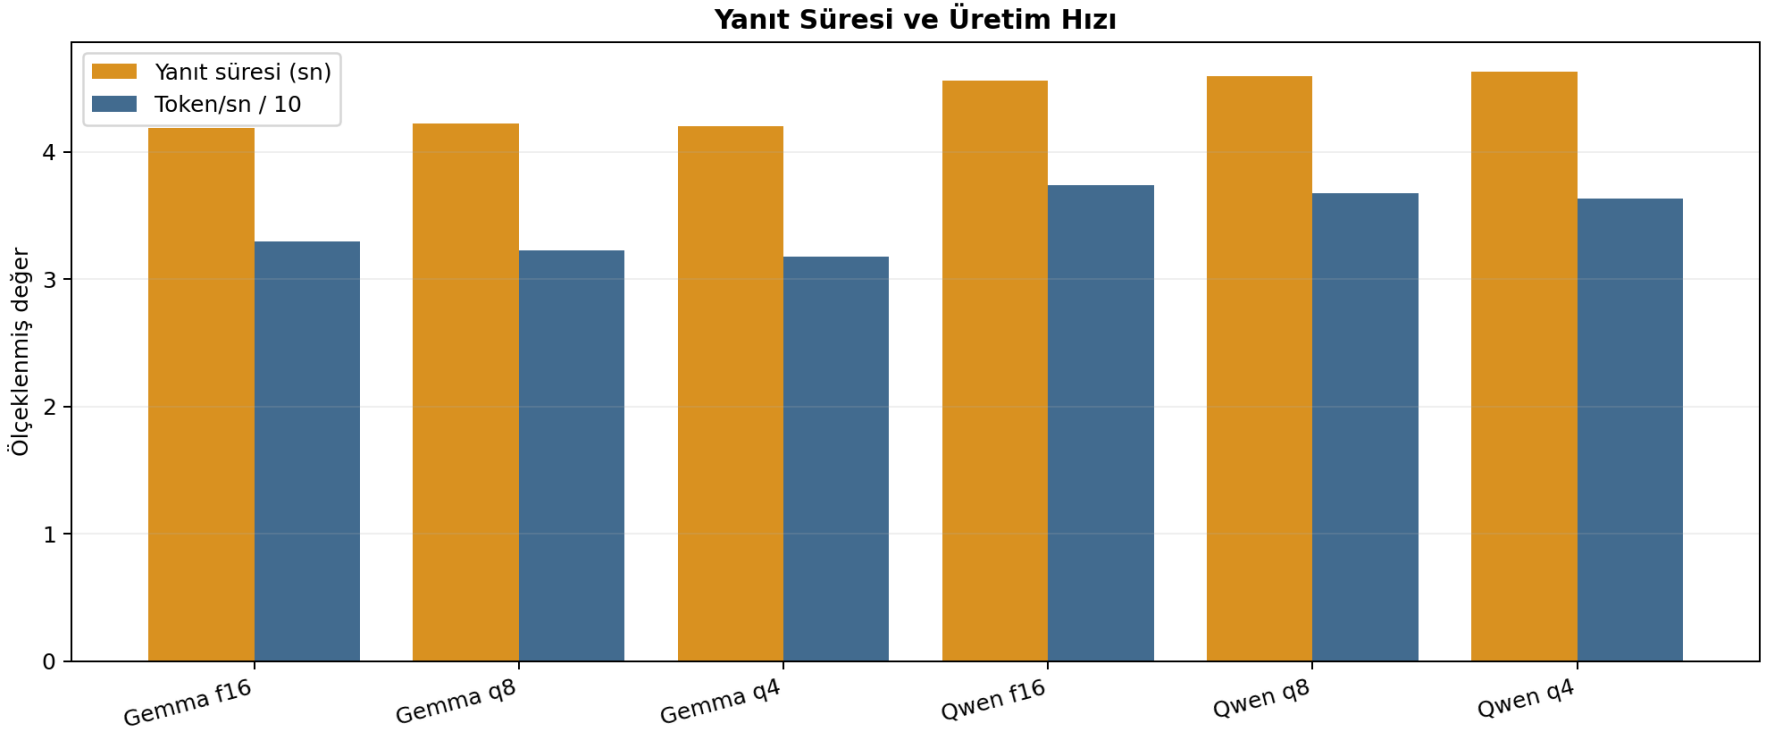
Ana okuma

Gemma-f16 en yüksek doğruluğu (7.44), Gemma-q4_0 ise en yüksek dayanaklılığı (6.99) verdi. Farklar küçüktür. Qwen-q4_0 doğrulukta Gemma-q4_0'a çok yaklaştı (7.39 ve 7.41), ancak daha yüksek high-risk sayısına sahipti (33 ve 23).

Qwen'in üretim token hızı daha yüksektir; buna karşın toplam yanıt süresi biraz daha uzundur. Bunun nedeni yanıt uzunluğu ve toplam üretilen token miktarının token/sn değerinden ayrı olmasıdır.

3. Grafikler


Classic Vector RAG Altında Kalite
Doğruluk
Dayanaklılık
Skor (0-10)
0
1
2
3
4
5
6
7
Gemma f16
Gemma q8
Gemma q4
Qwen f16
Qwen q8
Qwen q4


Yanıt Süresi ve Üretim Hızı
Yanıt süresi (sn)
Token/sn / 10
Ölçeklenmiş değer
0
1
2
3
4
Gemma f16
Gemma q8
Gemma q4
Qwen f16
Qwen q8
Qwen q4

4. Sonuç ve Öneri

KV kuantizasyonu bu parallel=1 deneyinde hız avantajı üretmedi: her iki modelde de f16 en yüksek token/sn değerini verdi. q4_0'ın temel faydası burada hızdan çok bellek tasarrufu potansiyelidir; bu rapor bellek tepe kullanımını karşılaştırmadığı için ayrıca ölçülmelidir.

Kalite-hız dengesi için Gemma-q4_0 güçlü ve güvenli varsayılan koşuldur: 7.41 doğruluk, 6.99 dayanaklılık ve en düşük high-risk sayısı. Yalnız ham doğruluk hedeflenirse Gemma-f16 çok küçük bir farkla liderdir.

Kaynak artifaktlar

data/results/kv_rag_classic_vector_20260722_150/
Her koşulda merged_results.csv, retrieved_chunks, server logları, evaluated_results_balanced_v2.csv ve summary_balanced_v2.json bulunur.