UYSM Değerlendirme Raporu

KV Cache Ablasyonu & RAG Ablasyonu · 150 soru · gpt-5.4-mini balanced-v2 jüri

Yönetici Özeti

> Bu rapor iki deney bloğunu tek birleşik kalite skoru (doğruluk, eksiksizlik ve dayanaklılığın 0-10 ortalaması) üzerinden karşılaştırır. Süre ve kalite ayrı görsellerde sunulur. KV cache tipleri parallel=1 protokolünde hız avantajı üretmedi; RAG bağlamı kaliteyi belirgin biçimde yükseltti. Speculative decoding bu rapora dahil değildir (veri eksik).

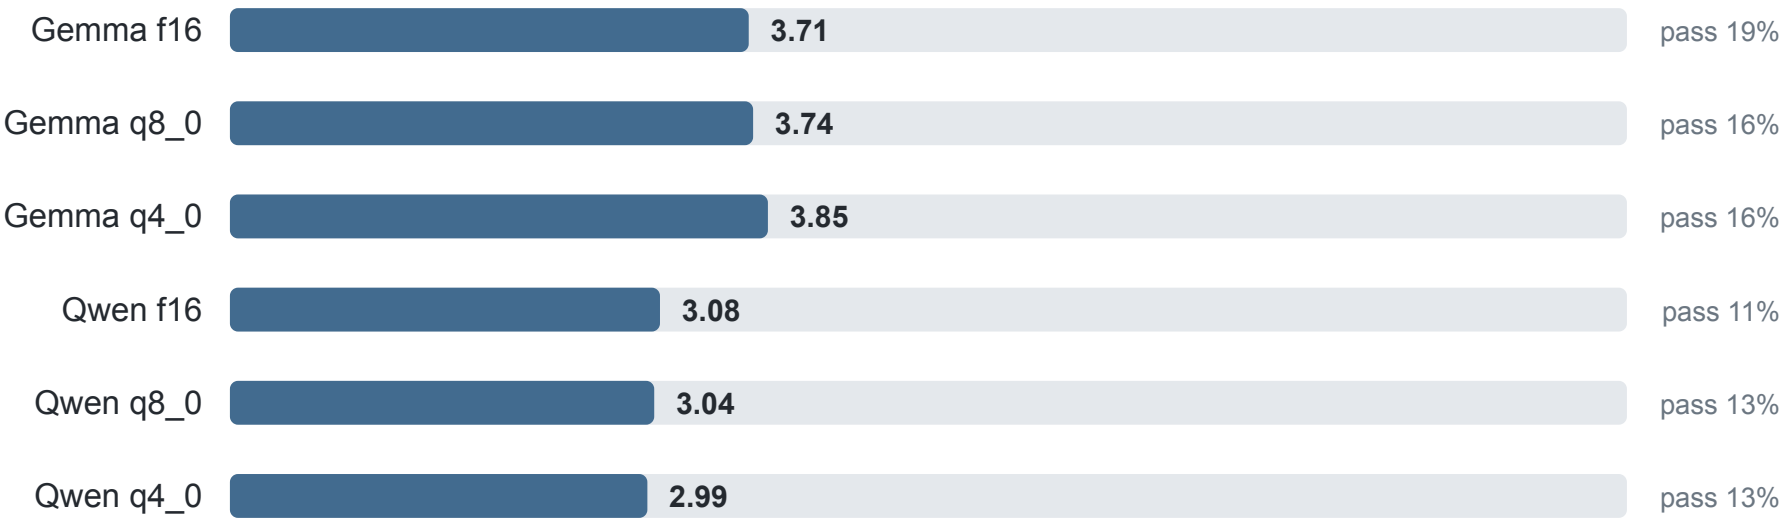
Sabit Protokol

Bileşen	Değer
Modeller	Gemma4 26B-A4B ve Qwen3.6 35B-A3B; Q4_K_M
KV cache	Simetrik K/V: f16, q8_0, q4_0
RAG	Classic/Smart × Vector/BM25; embeddinggemma:300m; k=10; threshold=0.55
Üretim	ctx 32768; parallel 1; Flash Attention açık; prompt cache kapalı; temperature 0; max 512
Jüri	gpt-5.4-mini; reasoning_effort=high; balanced-v2
Veri	final_qa_150.csv — sabit 150 soru

1. KV Cache Ablasyonu (RAG'sız, 6 koşul)

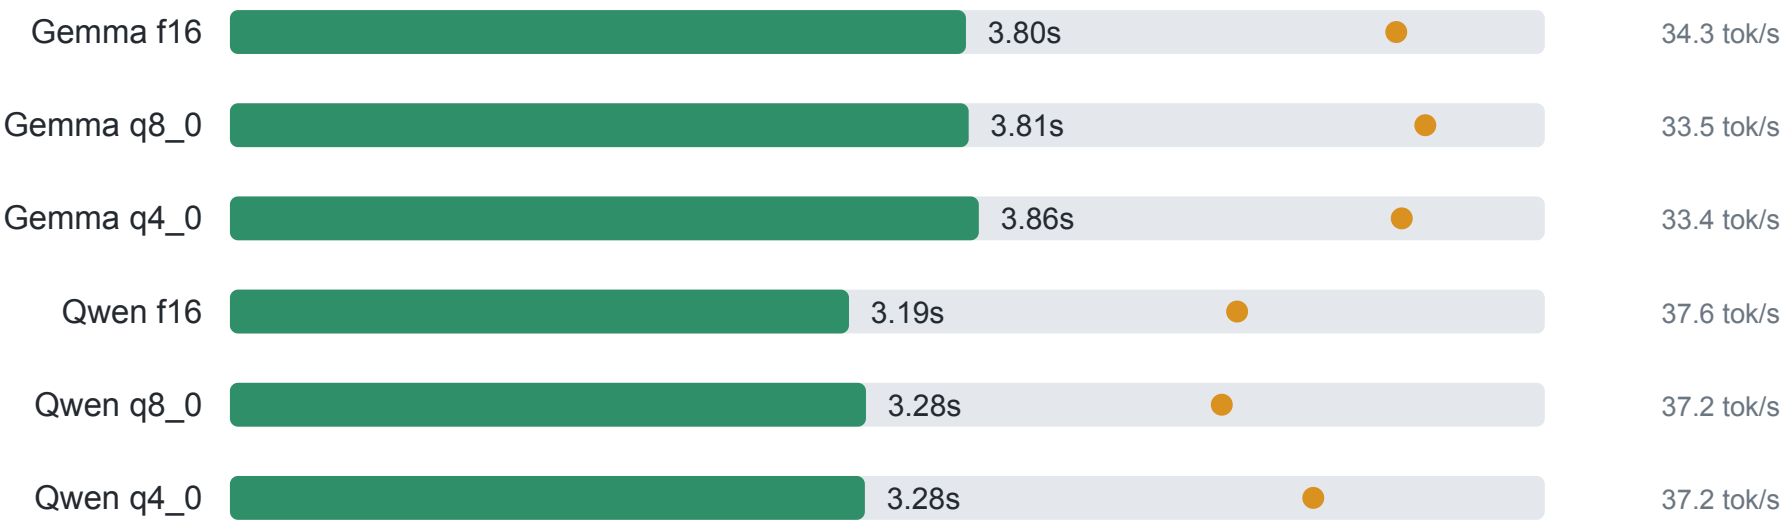
1a. Kalite Karşılaştırması

Birleşik Kalite Skoru — KV Cache (RAG'sız)



1b. Süre Karşılaştırması

Medyan Yanıt Süresi (nokta = p95, sağ = token/s)



1c. Alt-Skor Referans Tablosu

Koşul	Kalite (0-10)	Doğruluk	Eksiksizlik	Dayanaklılık	Pass %	Medyan sn	Ort. sn
Gemma f16	3.71	4.37	3.22	3.55	19%	3.80	3.83
Gemma q8_0	3.74	4.42	3.15	3.66	16%	3.81	3.83
Gemma q4_0	3.85	4.56	3.32	3.67	16%	3.86	3.90
Qwen f16	3.08	3.59	2.70	2.95	11%	3.19	3.25
Qwen q8_0	3.04	3.63	2.59	2.89	13%	3.28	3.44
Qwen q4_0	2.99	3.51	2.58	2.88	13%	3.28	3.30

2. RAG Ablasyonu

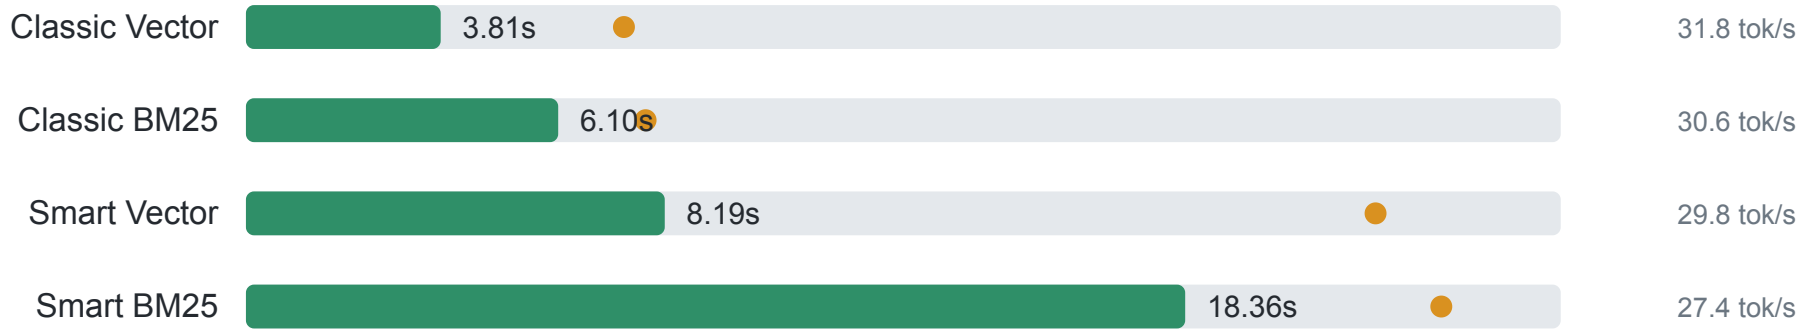
2a. RAG Yöntemleri — Kalite (Gemma-q4)

Birleşik Kalite Skoru — 4 RAG Yöntemi



2b. RAG Yöntemleri — Üretim Süresi

Üretim Süresi (retrieval hariç)



2c. Retrieval Süresi (ayrı)

Yöntem	Medyan retrieval
classic_vector	0.641s
classic_bm25	0.001s
smart_vector	0.708s
smart_bm25	0.090s

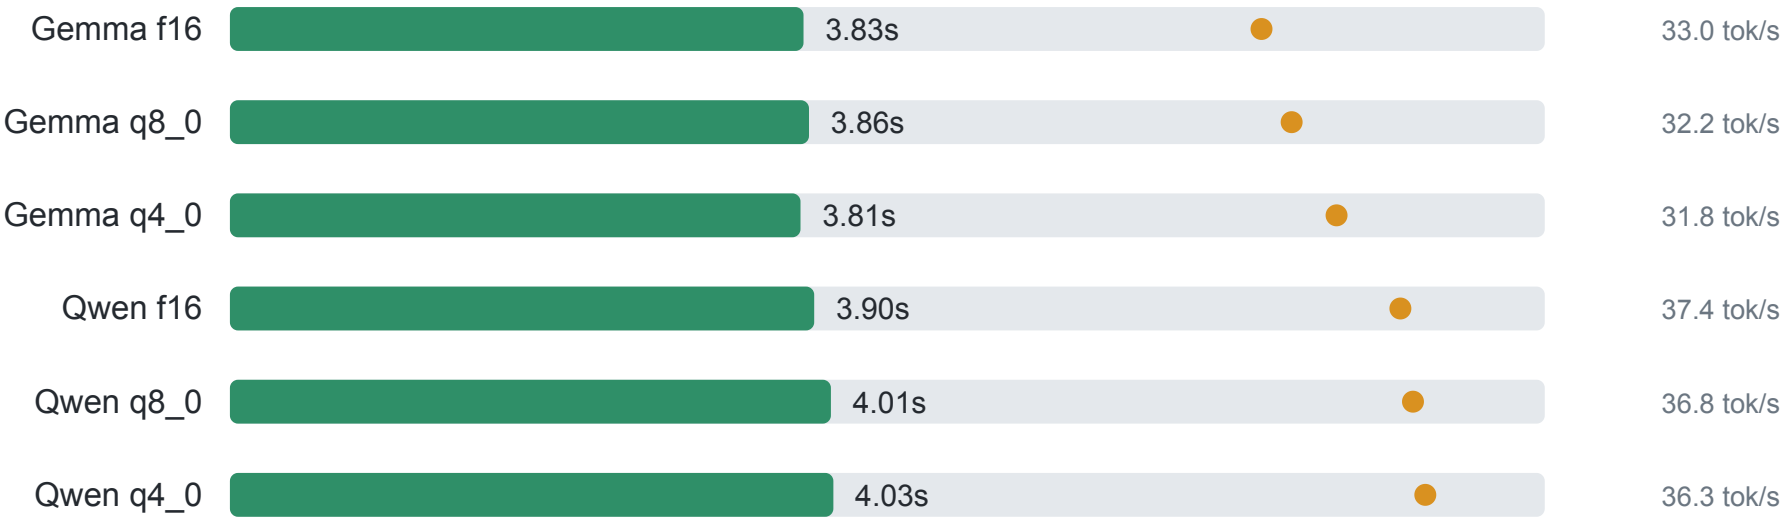
2d. Classic Vector RAG × KV Cache — Kalite

Birleşik Kalite Skoru — Classic Vector RAG



2e. Classic Vector RAG × KV Cache — Süre

Medyan Yanıt Süresi



Koşul	Kalite (0-10)	Doğruluk	Eksiksizlik	Dayanaklılık	Pass %	Medyan sn	Ort. sn
Gemma f16	7.03	7.44	6.75	6.91	59%	3.83	4.18
Gemma q8_0	6.93	7.33	6.69	6.77	57%	3.86	4.22
Gemma q4_0	7.07	7.41	6.80	6.99	58%	3.81	4.20
Qwen f16	6.82	7.27	6.30	6.90	55%	3.90	4.56
Qwen q8_0	6.82	7.27	6.35	6.86	57%	4.01	4.59
Qwen q4_0	6.93	7.39	6.45	6.95	57%	4.03	4.63

3. Sonuç & Sınırlılıklar

> RAG'sız KV ablasyonunda kalite skorları düşüktür (~3-4); RAG bağlamı altında belirgin yükselir (~7-8). Bu fark bağlam sağlamanın etkisidir, model kapasitesinin değil. KV kuantizasyonu bu tek-istek protokolünde hız kazandırmadı; faydası bellek tasarrufu potansiyelindedir (bu rapor tepe bellek ölçmez). Sonuçlar bu donanım, sabit 150 soru ve tek-istek protokolüne aittir; held-out genelleme iddiası taşımaz.