Gemma-q4_0
Dört RAG Yöntemi Karşılaştırması

150 soru | Classic/Smart x Vector/BM25 | 600 değerlendirme

Bu rapor yalnız Gemma4 26B-A4B ve q4_0 KV-cache ile dört retrieval yöntemini karşılaştırır. Retrieval süresi, üretim yanıt süresi ve kalite ayrı ölçülmüştür.

1. Yöntemler

Yöntem	Arama birimi	Gerçek ort. chunk	Önemli davranış
Classic Vector	1000 karakterlik chunk	4.75	Embedding benzerliği; 0.55 threshold nedeniyle bazı sorular boş
Classic BM25	1000 karakterlik chunk	10.00	Sözcüksel eşleşme; her soruda 10 pozitif eşleşme
Smart Vector	Child arama, parent dönüş	4.96	Kısa child ile eşleştirir, geniş parent bağlamı üretir
Smart BM25	Child BM25, parent dönüş	10.00	Sözcüksel child seçimi ve geniş parent bağlamı

Kontroller

Tüm yöntemler k=10 kullandı; vector yöntemlerinde threshold=0.55 ve embeddinggemma:300m kullanıldı. Model, KV-cache, prompt, üretim ayarları ve 150 soru sabittir. Configured k ile gerçek retrieved_chunk_size ayrı raporlanmıştır.

2. Birleşik Sonuçlar

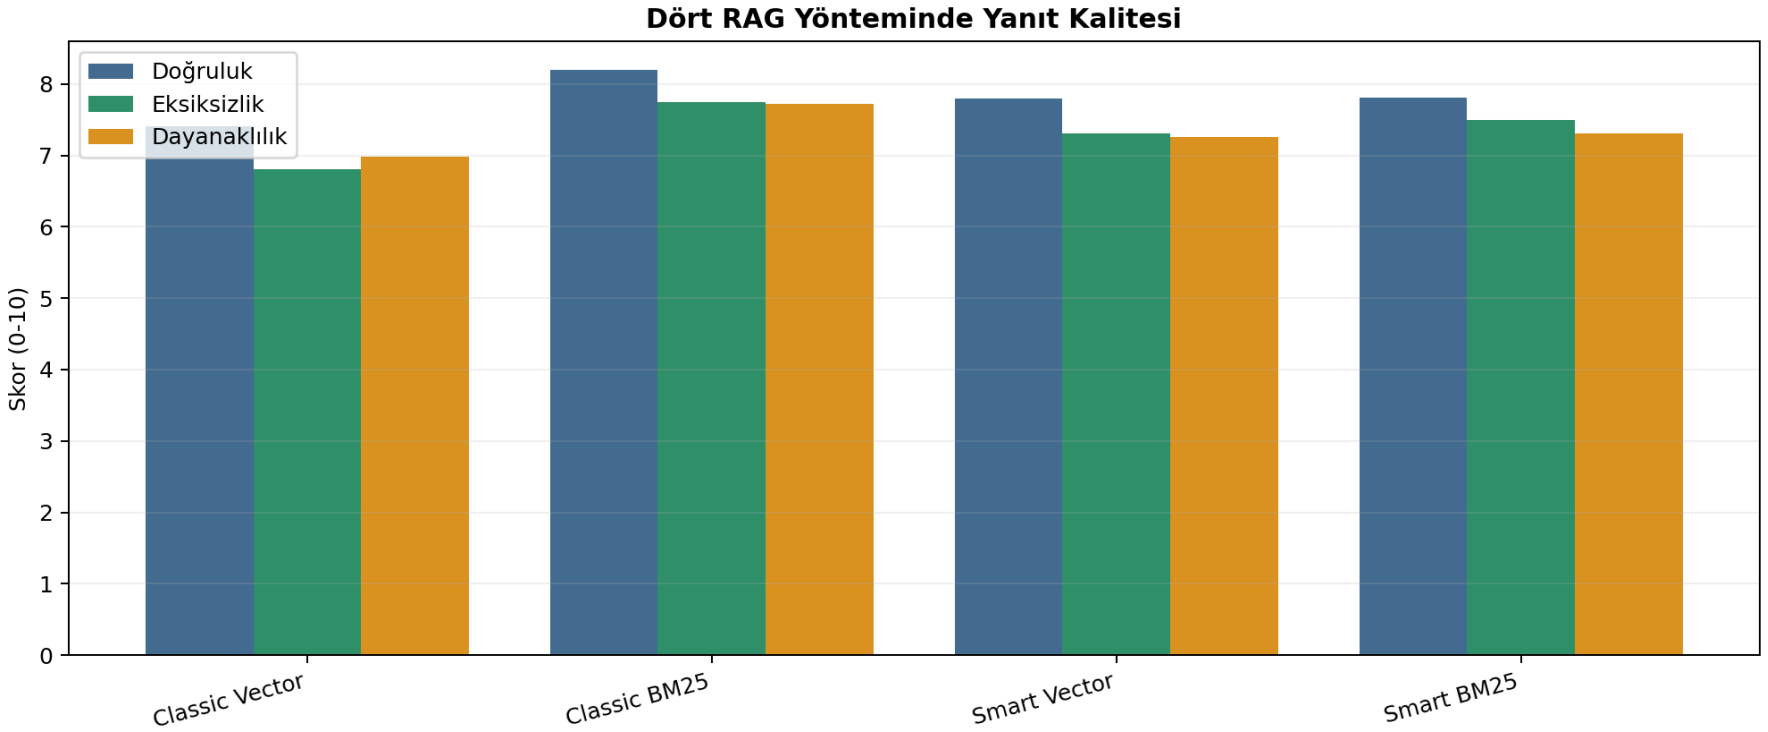
Yöntem	Doğr.	Eksik.	Day.	Pass	Fail	Ret. ort. sn	Ret. p95	Gen. ort. sn	Tok/sn
Classic Vector	7.41	6.80	6.99	87	32	0.842	1.208	4.20	31.78
Classic BM25	8.19	7.74	7.73	102	19	0.009	0.001	6.18	30.63
Smart Vector	7.80	7.31	7.25	99	27	0.784	1.133	10.45	29.75
Smart BM25	7.81	7.50	7.31	103	26	0.194	0.375	18.61	27.40

En iyi kalite

Classic BM25 en yüksek doğruluk (8.19), eksiksizlik (7.74) ve dayanaklılık (7.73) skorlarını verdi. Ayrıca 102 pass ve yalnız 19 fail ile en güçlü genel kalite profilini oluşturdu.

Smart BM25 103 pass ile bir adet daha fazla pass üretti; fakat ortalama skorları Classic BM25'ten düşük ve üretim süresi yaklaşık üç kat daha uzundu. Parent bağlamlarının büyüklüğü, daha düşük token/sn ve daha uzun üretim süresiyle birlikte maliyeti artırdı.

3. Kalite Grafiği



Vector yöntemleri daha az gerçek chunk döndürdü. Smart Vector, Classic Vector'a göre kaliteyi yükseltti; bu, parent genişletmenin bazı sorularda bağlam kapsamını iyileştirdiğini gösterir. Ancak Smart BM25, Classic BM25'i geçemedi.

Retrieval süreleri ayrı bir sıcak-cache taramasıdır. İlk istek maliyetleri max değerlerde görünür; üretim response_time_seconds alanına retrieval dahil değildir.

4. Sonuç ve Öneri

Bu sabit 150 soruluk benchmark için önerilen yöntem Classic BM25'tir. En yüksek üç kalite ortalamasını verirken üretim gecikmesi Smart yöntemlerden belirgin biçimde düşüktür. Classic Vector en düşük üretim gecikmesine sahiptir ancak 34 soruda bağlam boş kalması kaliteyi sınırlar.

Smart yöntemler ancak geniş parent bağlamının gerekli olduğu özel soru tiplerinde seçici olarak değerlendirilebilir. Genel varsayılan olarak kullanmak, özellikle Smart BM25'te yüksek gecikme cezası getirir.

Sınırlılıklar

Bu çalışma retrieval recall için ayrı gold-chunk etiketi içermez; burada ölçülen kalite son yanıta aittir. BM25'in sıcak-cache zamanları sürekli servis durumunu temsil eder. Sonuçlar tek koleksiyon, tek embedding modeli ve sabit 150 soru ile sınırlıdır; held-out genelleme iddiası taşımaz.

Kaynak artifaktlar

Classic Vector: data/results/kv_rag_classic_vector_20260722_150/gemma_q4_0/
Classic BM25: data/results/kv_rag_classic_bm25_20260722_150/gemma_q4_0/
Smart yöntemler ve retrieval timing: data/results/rag_methods_gemma_q4_20260722_150/