UYSM KV-Cache Ablasyon Değerlendirme Raporu

150 soruluk sabit benchmark | 2 model | 3 KV tipi | 6 koşul | 900 cevap

Bu rapor, Qwen3.6 ve Gemma4 modellerinin f16, q8_0 ve q4_0 simetrik KV-cache koşullarındaki kalite ve hız sonuçlarını özetler. Dengeli-v2 değerlendirmesi OpenAI gpt-5.4-mini ve yüksek akıl yürütme düzeyiyle yapılmıştır.

1. Amaç ve Kapsam

Amaç, model ailesi ve KV-cache veri tipinin aynı 150 soruluk mühendislik benchmark'ında cevap kalitesi ile çıkarım performansına etkisini kontrollü biçimde karşılaştırmaktır. Bu çalışma RAG içermez; sonuçlar daha sonra yapılacak RAG deneyinde kullanılacak tek model/KV koşulunu seçmek için üretilmiştir.

2. Deney Tasarımı

Bileşen	Sabit / Değer
Soru seti	final_qa_150.csv - 150 soru (140 cevaplanabilir, 10 cevaplanamaz)
Model aileleri	Qwen3.6 35B-A3B ve Gemma4 26B-A4B
Ağırlık kuantizasyonu	Q4_K_M
Deney değişkeni	Simetrik K/V cache: f16, q8_0, q4_0
llama.cpp ayarları	ctx 32768, parallel 1, Flash Attention açık, prompt cache kapalı
Üretim	temperature 0, max_tokens 512, düşünme kapalı
Değerlendirici	gpt-5.4-mini, reasoning_effort=high, balanced-v2
Başarı	900/900 inference ve 900/900 değerlendirme satırı başarılı

Kapsam notu: Bu sabit benchmark, held-out genelleme kanıtı değildir. KV-cache sonuçları tek istekli ve kısa/orta bağlamlı bu protokole aittir.

3. Değerlendirme Metrikleri

Metrik	Yorum
correctness_score (0-10)	Yanıtın ana iddialarının referansa göre doğruluğu
completeness_score (0-10)	Referanstaki gerekli noktaların kapsanma düzeyi
groundedness_score (0-10)	Yanıttaki iddiaların referansla desteklenme düzeyi
verdict	pass, partial veya fail
hallucination_risk	low, medium veya high
mean / p95 latency	Ortalama ve yüzde 95 uçtan uca yanıt süresi
generation tokens/s	Üretim aşaması token hızı
grounded refusal accuracy	Cevaplanamaz sorularda doğru biçimde yanıt vermeme oranı

Dengeli-v2 Rubriğinin Yorumu

Doğruluk, eksiksizlik ve dayanaklılık ayrı puanlanır. Zararsız ve doğru ek bağlam, doğruluğu otomatik olarak düşürmez; referansla desteklenmeyen ayrıntılar öncelikle dayanaklılık puanını etkiler. Yanlış, çelişkili, güvensiz veya eylemi değiştiren eklemeler ise doğruluğu düşürür ve halüsinasyon riskini artırır.

Karar etiketi model tarafından üretildiği için eşik-temelli deterministik bir sınıf değildir. Bu nedenle koşul seçiminin ana dayanağı sürekli skorlar, risk dağılımı ve hız metrikleridir.

4. Genel Sonuçlar

Metrik	900 kayıt geneli
Ortalama doğruluk	4.01/10
Ortalama eksiksizlik	2.93/10
Ortalama dayanaklılık	3.27/10
Pass / Partial / Fail	133 / 287 / 480
Low / Medium / High risk	195 / 276 / 429
Ortalama yanıt süresi	3.59 sn (koşul ortalamalarının ortalaması)
Başarılı kayıt	900 / 900

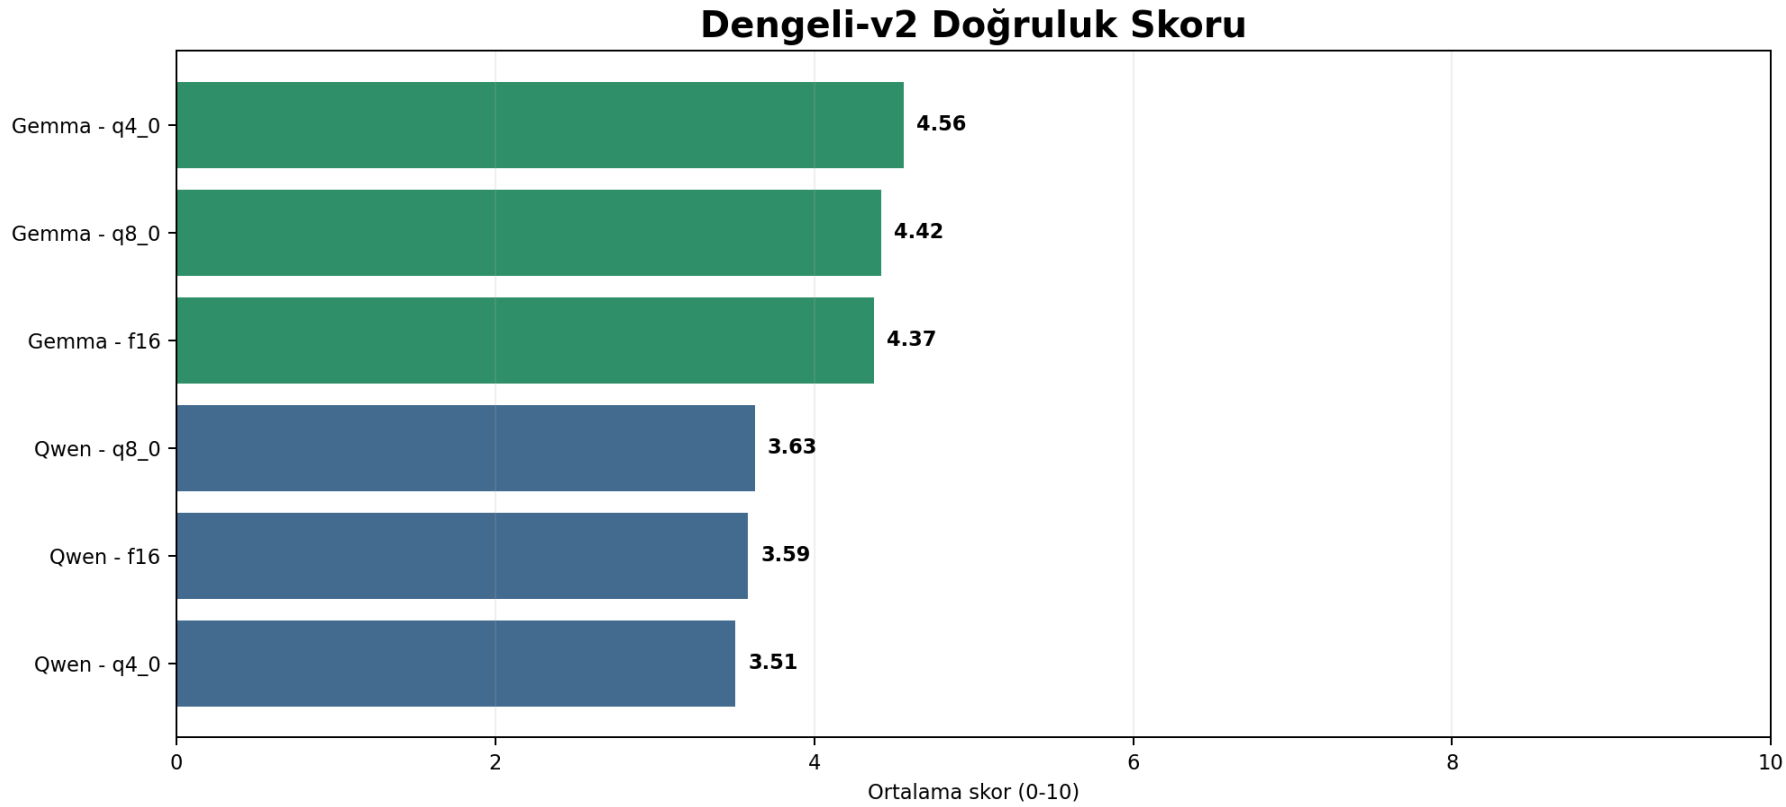
Gemma ailesi üç KV tipinde de Qwen'den daha yüksek kalite puanları üretmiştir. Qwen daha hızlıdır; ancak bu benchmark'ta hız farkı kalite farkını telafi etmemektedir. KV tipi kendi model ailesi içinde küçük kalite dalgalanmaları yaratmış, belirgin bir hız kazancı sağlamamıştır.

En Güçlü Koşul

Gemma - q4_0, en yüksek ortalama doğruluk (4.56) ve dayanaklı koşullardan biri (3.67) olmuştur. Ortalama yanıt süresi 3.90 sn'dir; Gemma - q8_0'a göre fark yaklaşık 0.07 sn'dir. Bu nedenle kontrollü RAG aşaması için önerilen koşuldur.

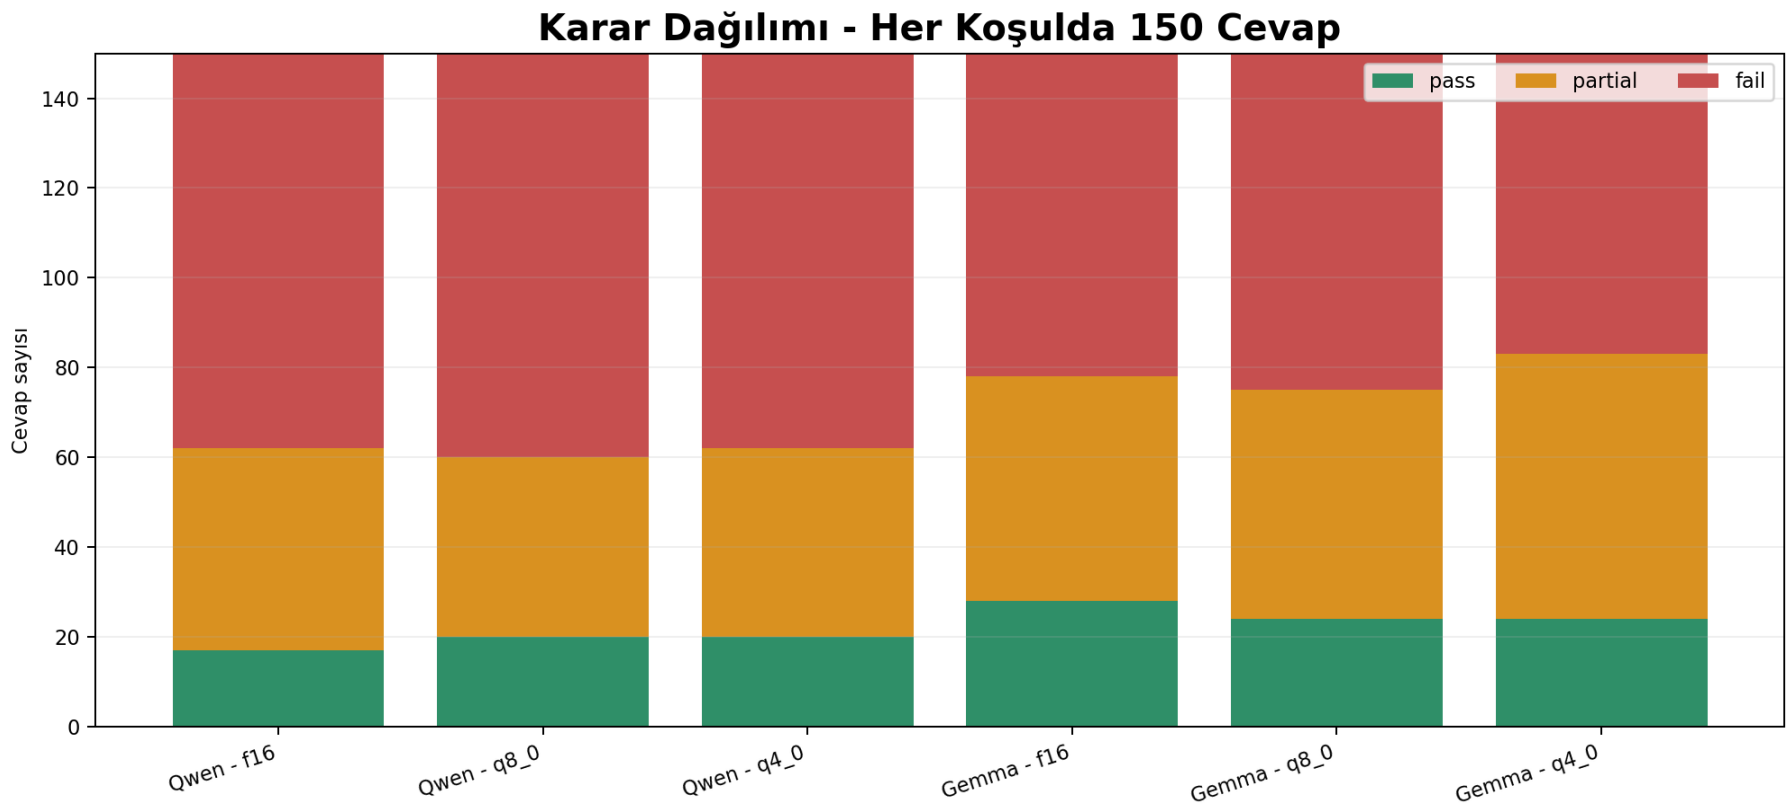
5. Görselleştirmeler

5.1 Ortalama doğruluk sıralaması



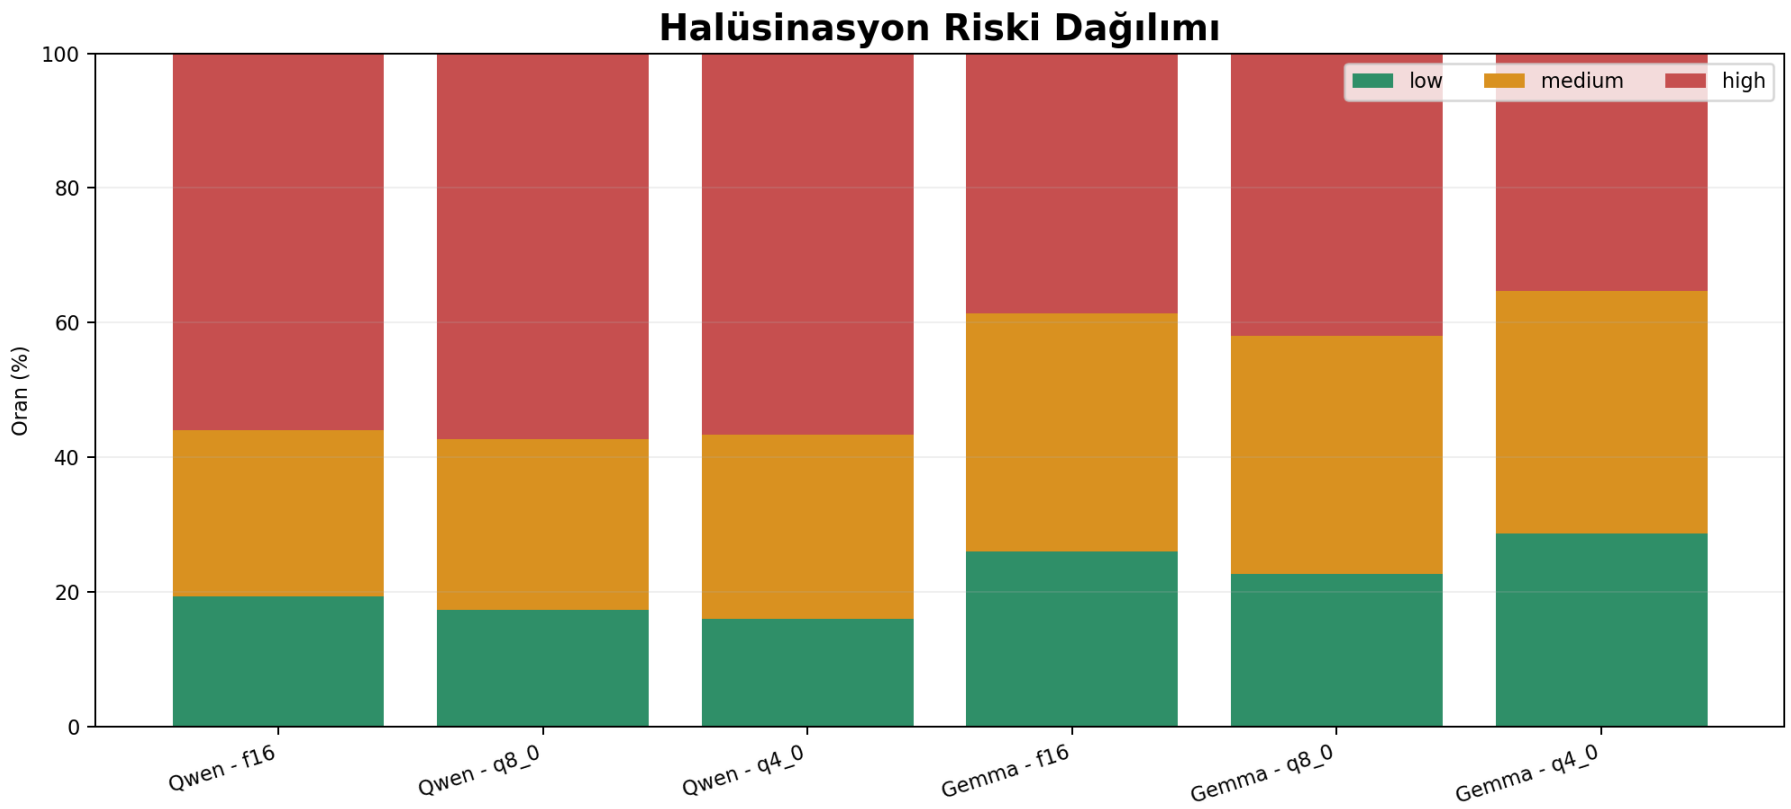
Gemma'nın üç koşulu ilk üç sıradadır. Aile içindeki farklar küçük olduğundan KV tipinin kalite etkisi, model ailesi etkisinden çok daha zayıf görünmektedir.

5.2 Pass / partial / fail dağılımı



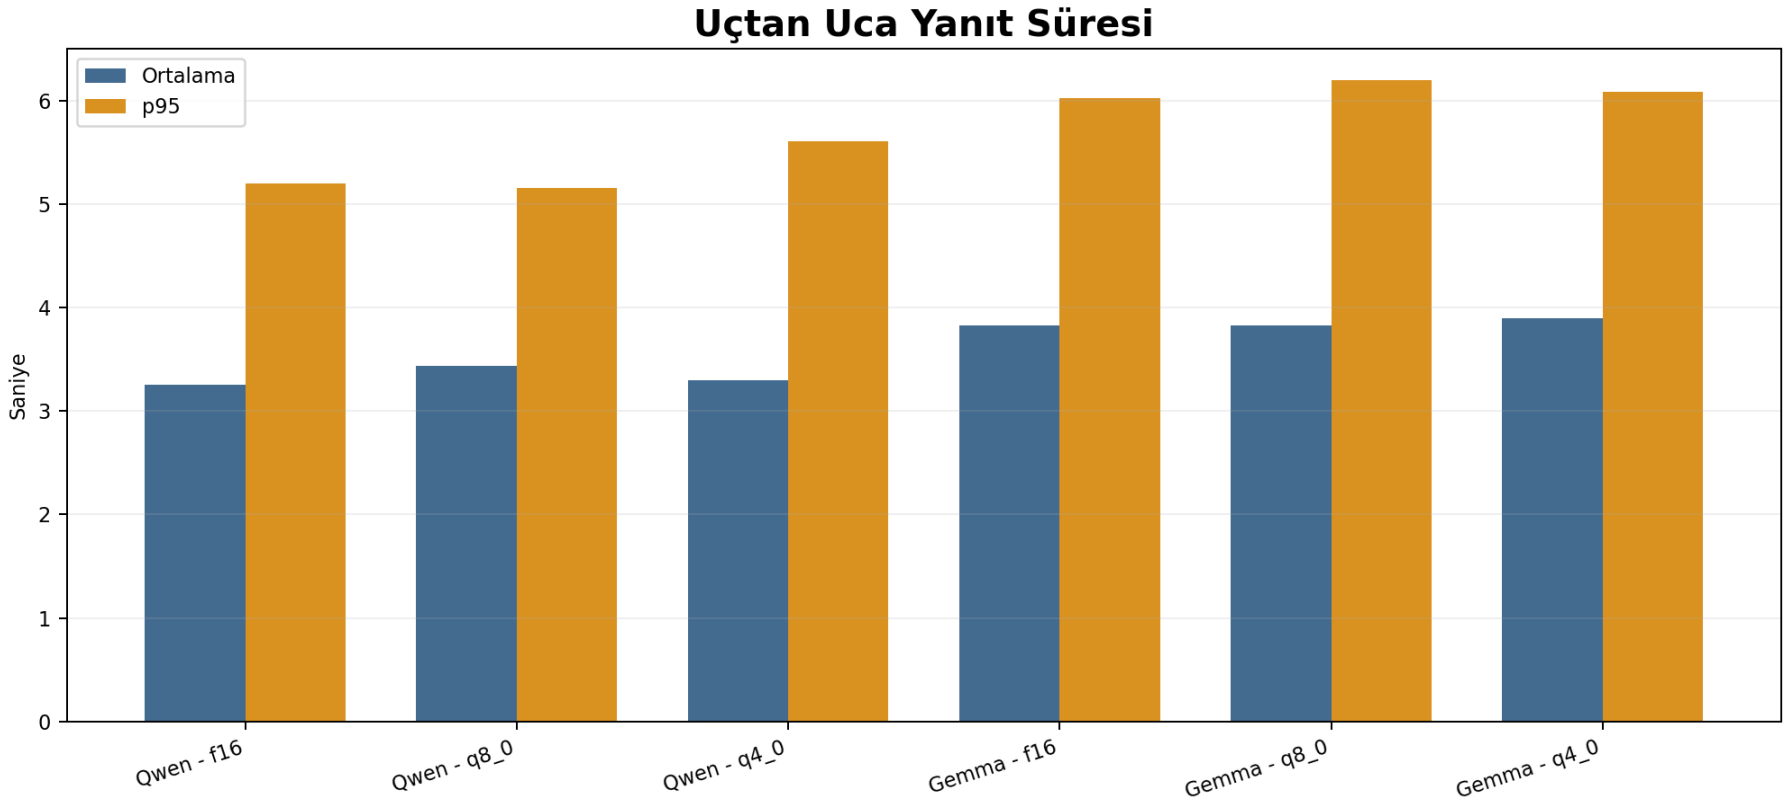
Gemma koşullarında fail sayısı Qwen koşullarına göre daha düşüktür. Bununla birlikte en iyi koşulda bile 150 cevabın 67'si fail etiketlidir; no-RAG cevap kalitesi üretim kullanımı için yeterli değildir.

5.3 Halüsinasyon riski



Qwen koşullarında high-risk oranı yaklaşık %56-57, Gemma koşullarında %35-42 aralığındadır. Risk dağılımı model ailesine güçlü biçimde bağlıdır; KV tipi bu tabloyu temelden değiştirmemiştir.

5.4 Yanıt süresi



Qwen koşulları ortalamada yaklaşık 3.25-3.44 sn, Gemma koşulları 3.83-3.90 sn aralığındadır. KV kuantizasyonu bu tek istekli protokolde istikrarlı bir hız avantajı sağlamamıştır.

6. Koşul Bazında Sıralama

Koşul	Doğr.	Eksik.	Day.	Pass	Partial	Fail	High %	Ort. sn	p95 sn	Tok/sn
Gemma - q4_0	4.56	3.32	3.67	24	59	67	35.3	3.90	6.09	33.35
Gemma - q8_0	4.42	3.15	3.66	24	51	75	42.0	3.83	6.20	33.46
Gemma - f16	4.37	3.22	3.55	28	50	72	38.7	3.83	6.02	34.34
Qwen - q8_0	3.63	2.59	2.89	20	40	90	57.3	3.44	5.16	37.23
Qwen - f16	3.59	2.70	2.95	17	45	88	56.0	3.25	5.20	37.61
Qwen - q4_0	3.51	2.58	2.88	20	42	88	56.7	3.30	5.61	37.21

Aile İçindeki KV Etkisi

Qwen'de en yüksek doğruluk q8_0 (3.63), Gemma'da q4_0 (4.56) ile ölçülmüştür. Ancak farklar küçük ve tek bir sabit benchmark'a aittir. Bu nedenle sonuç, KV kuantizasyonunun doğrudan kaliteyi artırdığı şeklinde genellenmemelidir.

Hız - Kalite Dengesi

Hedef	Öneri	Gerekçe
En yüksek kalite	Gemma - q4_0	En yüksek doğruluk; en yüksek eksiksizlik; güçlü dayanaklılık
Gemma içinde en düşük ortalama süre	Gemma - f16	3.83 sn; q8_0 ile pratik olarak aynı
En düşük ortalama süre	Qwen - f16	3.25 sn; fakat kalite belirgin biçimde düşük
RAG için kontrollü aday	Gemma - q4_0	Kalite lideri; Gemma q8_0'a göre yalnızca ~0.07 sn yavaş

7. Soru Bazında Gözlemler

Aşağıdaki tablolar, her soru için altı koşulun ortalama doğruluk skorunu gösterir. Konu etiketi üretilmemiştir; sorular raporda kısa metinle verilmiştir.

7.1 En yüksek ortalamalı beş soru

Soru	Ort. doğr.	Pass	High risk	Kısa soru metni
68	9.83	6	0	9 hatlı tahliyede birden fazla yaralıyı tek taleple bildirebiliyorum; peki MIST raporunu da hepsi için te...
120	9.83	6	0	Yan rüzgâr varsa roket hangi tarafa sapar?
10	9.67	6	0	M9 tıbbi yardım çantasını sahada sabit takıp da kullanabilir miyim, yoksa sadece sökülünce mi kullanılıyor?
87	9.67	6	0	Pusulada 70° istikametim var, geri dönüş yönünü hızlıca nasıl bulurum?
96	9.67	6	0	Arazide pusula iğnesi tam olarak neyi gösteriyor?

7.2 En düşük ortalamalı beş soru

Soru	Ort. doğr.	Pass	High risk	Kısa soru metni
59	0.00	0	6	IFAK Nesil I’de muayene eldiveni kaç tane var?
81	0.00	0	6	Aksam ileri gitmiyorsa muhtemel sebep ne olabilir?
115	0.00	0	6	Dürbün regulajında regulaj tahtasını göz lastiğinden ne kadar ileri koymalıyım?
17	0.17	0	6	Göğüs yaralanması için M9 çantada göğüs kapaması arıyorsam kaç tane çıkar?
32	0.17	0	6	Tahliye bakımının zamanında olup olmadığını hangi standartla değerlendiriyorlar?

8. Ana Bulgular

8.1 Model ailesi ana etkendir

Gemma, her KV tipinde Qwen'den daha yüksek doğruluk, eksiksizlik ve dayanaklılık üretmiştir.

8.2 KV kuantizasyonu hız kazandırmadı

q8_0 ve q4_0, bu parallel=1 ve kısa/orta bağlam protokolünde f16'ya karşı istikrarlı bir gecikme avantajı göstermemiştir. Olası fayda bellek ve eşzamanlılık başlığında ayrıca ölçülmelidir.

8.3 No-RAG kalite sınırlıdır

En iyi koşulun ortalama doğruluğu 4.56/10'dur. Bu sonuçlar bilgi erişimi olmadan model bilgisinin görev için yetersiz kaldığını gösterir; ancak RAG katkısı henüz bu raporda ölçülmemiştir.

8.4 Cevaplanamaz sorular kritik sorundur

Altı koşulun tamamında grounded refusal accuracy %0'dır. 10 cevaplanamaz soruda halüsinasyon oranı beş koşulda %100, Qwen-q8_0'da %90'dır.

8.5 Kontrollü RAG adayı

Gemma - q4_0, kalite liderliği ve küçük gecikme cezası nedeniyle sonraki dört RAG varyantı için seçilmelidir.

9. Sınırlılıklar

1. Benchmark 150 sabit sorudan oluşur; bağımsız held-out genelleme testi değildir.
2. Çalışma no-RAG koşuludur; retrieval kalitesi veya RAG katkısı hakkında doğrudan sonuç vermez.
3. Yalnızca iki model ailesi, Q4_K_M ağırlıklar ve simetrik K/V cache tipleri test edilmiştir.
4. parallel=1 ve mevcut soru uzunlukları, uzun bağlam ve çoklu eşzamanlı istek davranışını temsil etmez.
5. VRAM tepe kullanımı bu sonuç paketinde koşullar arasında karşılaştırılabilir bir rapor metriği olarak kaydedilmemiştir.
6. Kalite değerlendirmesi tek bir otomatik jüri modeline dayanır; dengeli-v2 ilk satırlarda elle kontrol edilmiş olsa da geniş insan doğrulaması yapılmamıştır.
7. LLM tarafından üretilen verdict etiketi, sürekli skorlarla her zaman deterministik biçimde uyumlu değildir.

10. Sonuç

Bu kontrollü 900-cevaplık deneyde Gemma4 26B-A4B, Qwen3.6 35B-A3B'den daha yüksek kalite üretmiş; Qwen ise daha hızlı çalışmıştır. KV-cache tipinin hız ve kalite üzerindeki etkisi model ailesi etkisine göre küçüktür. Gemma - q4_0, 4.56 doğruluk, 3.32 eksiksizlik ve 3.67 dayanaklılık ortalamalarıyla en güçlü koşuldur.

Güvenli özet: Sabit 150 soruluk no-RAG mühendislik benchmark'ında Gemma-q4_0 en yüksek dengeli-v2 kalite skorlarını verdi. KV kuantizasyonu parallel=1 koşulunda belirgin hız kazancı sağlamadı. Tüm koşullar cevaplanamaz sorularda yetersiz kaldığı için sonraki RAG testinde kaynak-yetersizliği durumunda açık ret talimatı zorunludur.

11. Önerilen Sonraki Adımlar

1. Gemma - q4_0 ile classic_bm25, classic_vector, smart_bm25 ve smart_vector koşullarını aynı 150 soru üzerinde çalıştırın.

2. Her soru/varyant için retrieve k=10 bağlamlarını önce dondurun; generation karşılaştırmasında aynı bağlamı kullanın.

3. Retrieval kalitesini generation kalitesinden ayrı raporlayın; configured k ile gerçek retrieved_chunk_size değerlerini ayırın.

4. RAG prompt'una bağlamda yanıt yoksa açıkça yanıt vermeme talimatı ekleyin ve 10 cevaplanamaz soruyu ayrı güvenlik metriği olarak izleyin.

5. Karar etiketi gerekiyorsa balanced-v2 sürekli skorlarından deterministik eşikler türetin; aynı cevapları yeniden LLM'e puanlatmadan raporlayın.

6. Uzun bağlam veya concurrency iddiası için ayrı bir stres testi planlayın; bu çalışmanın latency sonucunu o senaryolara genellemeyin.

Kaynak Artifaktlar

Ham ve değerlendirilmiş sonuçlar: data/results/kv_ablation_20260721_150/
Her koşul: raw_results.csv, evaluated_results_balanced_v2.csv ve summary_balanced_v2.json.
Değerlendirme sürümü: balanced-v2; jüri: gpt-5.4-mini; reasoning effort: high.

Rapor oluşturma tarihi: 22 Temmuz 2026