Speculative Decoding Deney Raporu

Qwen n-gram | Gemma n-gram | Gemma EAGLE-3 durum raporu

Bu rapor speculative decoding koşullarının çalıştırılma durumunu, performans çıktısını ve doğrulanmış sınırlılıkları açıkça ayırır. Eksik metrikler tahmin edilmemiştir.

1. Sabit Protokol

Bileşen	Değer
Hedef modeller	Qwen3.6 35B-A3B ve Gemma4 26B-A4B; Q4_K_M
KV-cache	q8_0 K/V
Sunucu	ctx 32768; parallel 1; Flash Attention açık; prompt cache kapalı
Üretim	temperature 0; max 512; thinking kapalı
n-gram	ngram-mod; match/min/max = 24/48/64
EAGLE-3	spec-draft-n-max=3; hedefe özgü draft GGUF gerekir
Veri	150 soru; bu speculative script RAG kullanmaz

Koşul	Durum	Satır	Ort. sn	p95 sn	Tok/sn	Acceptance	Balanced-v2
Qwen n-gram	failed	150	3.38	5.01	37.22	Logda yok	Bekliyor - API limiti
Gemma n-gram	failed	55	3.84	6.32	33.48	Logda yok	Bekliyor - API limiti
Gemma EAGLE-3	Bloke - draft GGUF yok	0	-	-	-	-	-

2. Bulguların Yorumu

n-gram inference satırları ve sunucu logları kaydedildi. Ancak mevcut llama.cpp sunucu logu aggregate accepted/generated token istatistiğini üretmedi; bu nedenle acceptance oranı raporlanamaz. Script bu alanı zorunlu tuttuğu için koşulu teknik olarak failed işaretleyebilir; bu, 150 inference satırının başarısız olduğu anlamına gelmez.

Gemma EAGLE-3 çalıştırılmadı çünkü /home/odine/models altında hedefe özgü Gemma draft GGUF bulunamadı. Başka bir draft modelle ikame yapılmadı; böyle bir ikame kontrollü deney tasarımını bozar.

Kalite değerlendirmesi

OpenAI kullanım limiti yeni speculative cevapları gpt-5.4-mini ile değerlendirme aşamasında doldu. KV ve RAG değerlendirmeleri tamamlandı; yalnız speculative kalite skorları bekliyor. Limit yenilendiğinde evaluate_balanced_v2.py ham CSV'ler üzerinde resume-safe biçimde çalıştırılabilir.

3. Sonuç

Speculative decoding için performans üretimi kısmen tamamlandı; n-gram koşullarında ham cevaplar ve zamanlama verisi mevcuttur. EAGLE-3 ve balanced-v2 kalite değerlendirmesi tamamlanmadan kesin bir kazanan ilan edilmemelidir. Ayrıca acceptance metriği için llama.cpp log formatı veya ayrı istemci/sunucu ölçümü düzeltilmelidir. Kaynaklar data/results/speculative_ablation_20260722_150/ altında saklanmıştır.